



PRA-SKRIPSI

METODE HIBRIDA *EFFICIENTNET-B0* DAN *PROTOTYPICAL NETWORK* UNTUK KLASIFIKASI MULTIKELAS PENYAKIT *DIABETIC RETINOPATHY*

ABI EKA PUTRA WULYONO
NPM 22081010190

DOSEN PEMBIMBING
Dr. Faisal Muttaqin, S.Kom, M.T
Budi Mukhamad Mulyo, S.Kom., MT

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
FAKULTAS ILMU KOMPUTER
PROGRAM STUDI INFORMATIKA
SURABAYA
2025

DAFTAR ISI

DAFTAR ISI.....	ii
DAFTAR TABEL.....	iv
DAFTAR GAMBAR	v
DAFTAR KODE.....	vi
DAFTAR ISTILAH	vii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	5
1.3 Batasan Masalah.....	5
1.4 Tujuan Penelitian	6
1.5 Manfaat Penelitian	6
BAB II TINJAUAN PUSTAKA.....	8
2.1 Penelitian Terdahulu	8
2.2 <i>Diabetic Retinopathy</i> (DR)	13
2.3 <i>EfficientNet-B0</i>	14
2.4 <i>Prototypical Network</i>	18
2.5 <i>Asia Pacific Tele-Ophthalmology Society (APROS) 2019 Dataset</i>	20
2.6 <i>Preprocessing</i>	22
2.6.1 <i>Circle Crop</i>	22
2.6.2 <i>Enhanced Green</i>	23
2.7 Metrik Evaluasi Klasifikasi.....	23
2.7.1 <i>Confusion Matrix</i>	24
2.7.2 <i>Accuracy</i>	24
2.7.3 <i>Precision</i>	25
2.7.4 <i>Recall</i>	25
2.7.5 <i>F1-Score</i>	26
2.7.6 <i>Macro-Averaging</i>	26
2.7.7 <i>Quadratic Weighted Kappa (QWK)</i>	27
BAB III METODOLOGI.....	29
3.1 Tahapan Penelitian	29

3.2 Studi Literatur	30
3.3 Persiapan Data.....	30
3.3.1 APTOS <i>Dataset</i> 2019.....	31
3.3.2 Analisis Distribusi Kelas.....	31
3.3.3 Pembagian Data <i>Train</i> dan <i>Test</i>	32
3.4 <i>Preprocessing</i>	33
3.4.1 <i>Circle Crop</i>	33
3.4.2 <i>Enhanced Green</i>	34
3.4.3 Normalisasi dan <i>Resize</i>	34
3.5 Pembangunan Model Hibrida	34
3.5.1 <i>EfficientNet-B0</i> sebagai <i>Feature Extractor</i>	35
3.5.2 <i>Prototypical Network</i> sebagai <i>Classifier</i>	36
3.5.3 Integrasi Hibrida <i>EfficientNet-B0 & Prototypical Network</i>	37
3.6 <i>Train</i> dan <i>Test</i> Model.....	38
3.6.1 Proses <i>Train</i> Model.....	39
3.6.2 Metrik Evaluasi	40
3.6.3 Model Pembanding (<i>Baseline</i>).....	41
3.6.4 Analisis Hasil	42
BAB IV HASIL DAN PEMBAHASAN	43
BAB V KESIMPULAN DAN SARAN.....	43
DAFTAR PUSTAKA	44

DAFTAR TABEL

Tabel 2.1.1 Penelitian Terdahulu	12
Tabel 2.3.1 Varian EfficientNet	16

DAFTAR GAMBAR

Gambar 2.3.1 <i>Compound Scaling</i>	15
Gambar 2.3.2 Arsitektur <i>EfficientNet-B0</i>	17
Gambar 2.4.1 <i>Arsitektur Prototypical Network</i>	20
Gambar 3.1.1 Tahapan Penelitian	29
Gambar 3.3.1 Citra masing-masing kelas	31
Gambar 3.3.2 Distribusi kelas <i>Dataset APTOS 2019</i>	32
Gambar 3.3.3 Skema pembagian <i>Dataset</i>	32
Gambar 3.4.1 Contoh Hasil <i>Enhanced Green</i>	34
Gambar 3.5.1 Alur <i>Feature Extraction</i> untuk <i>EfficientNet-B0</i>	35
Gambar 3.5.2 Alur <i>Classifier</i> untuk <i>Prototypical Network</i>	36
Gambar 3.5.3 Alur Hibrida	38

DAFTAR KODE

DAFTAR ISTILAH

BAB I

PENDAHULUAN

1.1 Latar Belakang

Diabetic Retinopathy (DR) merupakan komplikasi mikrovaskular dari diabetes mellitus yang menyebabkan kerusakan progresif pada pembuluh darah retina [1], [2]. Kondisi ini dapat berkembang menjadi gangguan penglihatan hingga kebutaan permanen jika tidak terdeteksi dan ditangani secara dini [3]. Berdasarkan hasil penelitian berskala global, prevalensi DR pada individu dengan diabetes mencapai 22,27%, dengan 6,17% di antaranya tergolong *vision-threatening Diabetic Retinopathy* (VTDR), dan angka ini diperkirakan meningkat menjadi 160,5 juta kasus pada tahun 2045 [4]. Penelitian lain juga menunjukkan bahwa jumlah penderita DR terus meningkat dalam 20 tahun terakhir, dari 10,9% pada tahun 2007 menjadi 20,8% pada tahun 2021, yang menunjukkan semakin besarnya beban penyakit ini di Masyarakat [5]. Berdasarkan karakteristik klinis yang diamati, *Diabetic Retinopathy* diklasifikasikan ke dalam beberapa tingkat keparahan, mulai dari stadium ringan hingga stadium lanjut yang bersifat proliferatif, di mana setiap tingkatan memerlukan pendekatan penanganan yang berbeda [6]. Mengingat progresivitas penyakit ini dapat dicegah melalui intervensi dini, deteksi dan klasifikasi *Diabetic Retinopathy* menjadi aspek krusial dalam manajemen kesehatan mata pada populasi penderita diabetes.

Deteksi *Diabetic Retinopathy* secara konvensional dilakukan melalui evaluasi citra fundus retina oleh tenaga medis spesialis oftalmologi. Dalam proses ini, dokter spesialis mengidentifikasi berbagai indikator patologis pada retina, seperti mikroaneurisma, perdarahan, eksudat, dan neovaskularisasi, untuk menentukan tingkat keparahan penyakit [7]. Meskipun metode ini dapat memberikan hasil yang akurat, proses pemeriksaan bergantung pada ketersediaan tenaga ahli dan dapat bervariasi dalam hal konsistensi interpretasi antar evaluator [8]. Keterbatasan ini mendorong pengembangan sistem berbasis komputer untuk mendukung proses diagnosis medis, yang dikenal sebagai *computer-aided diagnosis* (CAD). Sistem CAD bertujuan untuk menyediakan

analisis objektif dan konsisten terhadap citra medis, sehingga dapat membantu tenaga medis dalam proses pengambilan keputusan diagnostik [9].

Dalam bidang *computer-aided diagnosis*, metode *deep learning* telah banyak digunakan karena kemampuannya dalam mempelajari representasi fitur dari data secara otomatis tanpa memerlukan perancangan fitur manual [10]. *Convolutional Neural Network* (CNN) merupakan salah satu arsitektur *deep learning* yang paling banyak digunakan, dirancang untuk memproses data berbentuk *grid* seperti citra, melalui mekanisme konvolusi yang mampu mengenali pola spasial lokal secara efektif pada data visual [11]. Salah satu penelitian menunjukkan bahwa model CNN dapat mengklasifikasikan tingkat keparahan *Diabetic Retinopathy* hingga mencapai akurasi 90,6% [12].

Seiring dengan perkembangan arsitektur *deep learning*, berbagai varian CNN modern telah dikembangkan dengan fokus pada peningkatan efisiensi dan performa model. Beberapa arsitektur yang telah banyak digunakan dalam aplikasi *computer vision* antara lain *ResNet*, *DenseNet*, dan *EfficientNet* [13]. Di antara berbagai arsitektur tersebut, *EfficientNet* telah menunjukkan performa yang kompetitif dalam berbagai aplikasi *computer vision* dengan menggunakan pendekatan *compound scaling* untuk menyeimbangkan tiga dimensi jaringan neural, yaitu kedalaman, lebar, dan resolusi input [14]. Pendekatan ini memungkinkan peningkatan kapasitas model secara proporsional tanpa penambahan kompleksitas yang tidak efisien. *EfficientNet* memiliki beberapa varian dengan tingkat kompleksitas yang berbeda, mulai dari B0 hingga B7, di mana setiap varian mewakili *trade-off* antara akurasi dan efisiensi komputasi [14].

Varian *EfficientNet-B0* merupakan versi dasar dari keluarga *EfficientNet* yang dikembangkan melalui neural architecture search [14]. *EfficientNet-B0* memiliki jumlah parameter yang relatif lebih sedikit dibandingkan varian lainnya[14]. Arsitektur ini menggunakan *mobile inverted bottleneck convolution* (MBConv) sebagai *building block* utama, yang memungkinkan ekstraksi fitur secara efisien dengan penggunaan memori dan operasi komputasi yang lebih rendah [14], [15]. Karakteristik arsitektur *EfficientNet-B0* yang menerapkan *compound scaling* untuk menyeimbangkan kedalaman, lebar, dan

resolusi jaringan menjadikannya sesuai sebagai backbone ekstraksi fitur pada aplikasi klasifikasi citra medis, khususnya pada citra fundus retina yang memerlukan kemampuan mendeteksi detail halus seperti mikroaneurisma, perdarahan, dan eksudat [16].

Salah satu tantangan dalam pengembangan model klasifikasi *Diabetic Retinopathy* adalah distribusi data yang tidak seimbang antar kelas. *Dataset* publik yang digunakan dalam penelitian, seperti APTOS 2019, menunjukkan variasi jumlah sampel yang signifikan pada tiap tingkat keparahan, sehingga menimbulkan ketimpangan representasi antara kelas ringan, sedang, berat, dan proliferatif [17], [18], [19]. Ketidakseimbangan kelas pada *Dataset* medis dapat menyebabkan model *deep learning* cenderung bias terhadap kelas dengan jumlah sampel lebih banyak, sehingga performa pada kelas yang kurang terwakili menurun [20].

Salah satu pendekatan yang dikembangkan untuk mengatasi keterbatasan jumlah data beranotasi pada citra medis adalah *few-shot learning*, yaitu metode yang dapat mengurangi permasalahan kelangkaan data dan meningkatkan kecepatan serta ketahanan analisis citra medis dengan menggunakan jumlah contoh pelatihan yang terbatas per kelas [21]. *Few-shot learning* berbeda dengan supervised learning konvensional yang memerlukan data berlimpah untuk setiap kelas, karena berfokus pada pembelajaran representasi yang dapat digeneralisasi dari hanya beberapa contoh [21]. Dalam konteks *few-shot learning*, berbagai pendekatan *meta-learning* telah dikembangkan, yang umumnya dikategorikan menjadi tiga kelompok utama, yaitu *metric-based*, *model-based*, dan *optimization-based learning* [22]. Di antara ketiganya, pendekatan *metric-based learning* beroperasi dengan mempelajari fungsi jarak atau kesamaan (*similarity function*) dalam ruang *embedding*, sehingga model dapat membandingkan sampel baru dengan representasi kelas yang telah dipelajari selama proses *meta-training*.

Prototypical Network merupakan salah satu metode *metric-based few-shot learning* yang membangun representasi prototipe untuk setiap kelas dalam ruang *embedding* berdimensi tinggi [23]. Metode ini bekerja dengan menghitung *centroid* atau rata-rata dari *embedding* sampel *support set* untuk

setiap kelas sebagai prototipe kelas tersebut [23], [24]. Klasifikasi sampel *query* kemudian dilakukan berdasarkan jarak *Euclidean* antara *embedding* sampel *query* dengan prototipe setiap kelas, di mana sampel diklasifikasikan ke kelas dengan jarak terdekat [23]. Pendekatan ini memungkinkan model untuk mengenali kelas dengan jumlah sampel terbatas melalui pembelajaran representasi yang diskriminatif dalam ruang *embedding* [23], [25]. *Prototypical Network* telah diterapkan dalam berbagai domain klasifikasi, termasuk *computer vision* dan *medical imaging*, dengan hasil yang menunjukkan kemampuan dalam menangani kondisi data tidak seimbang [26].

Penelitian sebelumnya telah mengeksplorasi penggunaan *EfficientNet* sebagai *backbone* untuk ekstraksi fitur pada klasifikasi *Diabetic Retinopathy*, serta penerapan *Prototypical Network* untuk menangani kondisi *few-shot learning* pada berbagai domain aplikasi [16], [17], [18], [19], [24], [25], [26], [27]. Namun, berdasarkan penelusuran literatur, belum ditemukan penelitian yang secara spesifik mengembangkan model hibrida *EfficientNet-B0* dan *Prototypical Network* untuk klasifikasi multikelas *Diabetic Retinopathy* pada *Dataset APTOS 2019*. Model hibrida dalam konteks ini merujuk pada integrasi *end-to-end* antara *EfficientNet-B0* sebagai *feature extractor* dengan *Prototypical Network* sebagai *classifier*, di mana kedua komponen dilatih secara bersama-sama melalui *backpropagation* untuk mengoptimalkan representasi *embedding* dan pembentukan prototipe secara simultan. Pendekatan hibrida ini berbeda dengan pendekatan konvensional yang menggunakan *EfficientNet* dan metode klasifikasi secara terpisah, karena memungkinkan pembelajaran representasi fitur yang lebih adaptif terhadap karakteristik *few-shot learning* dan ketidakseimbangan distribusi kelas.

Berdasarkan permasalahan dan peluang yang telah diuraikan, penelitian ini bertujuan untuk mengembangkan model hibrida yang mengintegrasikan *EfficientNet-B0* sebagai *backbone* ekstraksi fitur dengan *Prototypical Network* sebagai mekanisme klasifikasi untuk menangani klasifikasi multikelas *Diabetic Retinopathy* dengan lima tingkat keparahan (0-4). Model hibrida ini dilatih secara *end-to-end*, memungkinkan optimasi bersama antara ekstraksi fitur dan pembentukan prototipe kelas. Penelitian ini diharapkan dapat memberikan

kontribusi pada pengembangan metode klasifikasi *Diabetic Retinopathy*, khususnya dalam konteks penanganan ketidakseimbangan distribusi kelas melalui integrasi *few-shot learning* dengan arsitektur CNN yang efisien.

1.2 Rumusan Masalah

Berdasarkan uraian latar belakang yang telah dijelaskan, terdapat beberapa permasalahan utama yang perlu dipecahkan dalam penelitian ini, yaitu:

1. Bagaimana penerapan model hibrida *EfficientNet-B0* dan *Prototypical Network* untuk klasifikasi multikelas *Diabetic Retinopathy*?
2. Bagaimana pengaruh integrasi *Prototypical Network* terhadap performa klasifikasi dibandingkan model *baseline*?

1.3 Batasan Masalah

Berdasarkan penjabaran rumusan masalah yang telah disebutkan sebelumnya, terdapat beberapa batasan masalah yang ditentukan agar penelitian ini tidak terlalu luas dan lebih terfokus pada permasalahan yang akan diselesaikan. Berikut merupakan batasan masalah pada penelitian ini:

1. *Dataset* yang digunakan adalah APTOS 2019, sehingga hasil penelitian hanya diuji pada distribusi dan karakteristik *Dataset* tersebut. Data eksternal dari sumber lain tidak termasuk dalam lingkup pelatihan dan evaluasi.
2. Fokus penelitian terbatas pada citra fundus retina untuk klasifikasi multikelas *Diabetic Retinopathy* dengan lima tingkat keparahan (0: *No DR*, 1: *Mild*, 2: *Moderate*, 3: *Severe*, 4: *Proliferative DR*).
3. Penelitian menggunakan model hibrida dengan *EfficientNet-B0* sebagai *backbone feature extractor* dan *Prototypical Network* sebagai *classifier* yang dilatih secara *end-to-end*. Arsitektur *backbone* lain seperti *ResNet*, *DenseNet*, atau *transformer-based models* tidak termasuk dalam lingkup penelitian ini.
4. *Preprocessing* citra terbatas pada teknik *Circle Crop* dan *Enhanced Green*. Teknik augmentasi data sintetis atau metode *preprocessing* lainnya tidak digunakan untuk menjaga integritas informasi medis pada citra fundus.

5. Penanganan ketidakseimbangan kelas difokuskan pada pendekatan *few-shot learning* melalui *Prototypical Network*, tanpa menggunakan teknik *resampling* atau *synthetic data generation*.
6. Evaluasi performa model menggunakan metrik klasifikasi yang mencakup *accuracy*, *macro-precision*, *macro-recall*, *macro-F1-score*, *confusion matrix*, dan *quadratic weighted kappa* (QWK) untuk menilai keseimbangan performa model dalam mengenali setiap kelas, khususnya pada kelas minoritas, pada *Dataset APTOS 2019*. Evaluasi dilakukan dengan pembagian data menjadi *training* dan *validation* set, tanpa pengujian pada *dataset* eksternal lainnya.

1.4 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, penelitian ini mempunyai tujuan sebagai berikut:

1. Menerapkan model hibrida *EfficientNet-B0* dan *Prototypical Network* dalam klasifikasi multikelas citra *Diabetic Retinopathy*.
2. Menganalisis pengaruh integrasi *Prototypical Network* sebagai *classifier* terhadap performa klasifikasi dibandingkan dengan model *baseline*.

1.5 Manfaat Penelitian

Berdasarkan tujuan penelitian yang telah disebutkan sebelumnya, didapatkan beberapa gambaran manfaat penelitian ini. Gambaran manfaat penelitian ini adalah sebagai berikut:

1. Bagi Peneliti, penelitian ini memberikan kesempatan untuk mengimplementasikan ilmu yang diperoleh selama perkuliahan, khususnya dalam bidang *deep learning*, *few-shot learning*, dan *computer-aided diagnosis* pada klasifikasi citra medis. Penelitian ini juga melatih kemampuan analisis dan pemecahan masalah dalam mengembangkan model hibrida serta strategi penanganan ketidakseimbangan kelas pada *Dataset* medis.
2. Bagi Bidang Kesehatan, hasil penelitian ini dapat menjadi kontribusi dalam pengembangan sistem *computer-aided diagnosis* untuk deteksi dan

klasifikasi *Diabetic Retinopathy* secara objektif dan konsisten. Model yang dikembangkan berpotensi untuk mendukung tenaga medis dalam proses skrining *Diabetic Retinopathy*.

3. Bagi Akademisi dan Peneliti Lanjutan, penelitian ini dapat menjadi referensi bagi mahasiswa, peneliti, atau praktisi yang tertarik dalam pengembangan sistem berbasis *few-shot learning dan integrasi arsitektur EfficientNet-B0* untuk klasifikasi citra medis dengan ketidakseimbangan kelas. Selain itu, penelitian ini memperkaya literatur mengenai penerapan *Prototypical Network* pada domain *medical imaging* dan dapat menjadi dasar pengembangan metode serupa pada penyakit atau modalitas citra medis lainnya.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Perkembangan teknologi *deep learning* telah membuka peluang besar dalam klasifikasi citra fundus retina dengan berbagai pendekatan arsitektur, mulai dari CNN konvensional hingga model hibrida yang mengombinasikan beberapa metode modern. Pendekatan ini memungkinkan model untuk mengekstraksi fitur spasial dan tekstur kompleks dari citra retina secara efisien serta menyesuaikan diri terhadap variasi kualitas citra. Penelitian ini berfokus pada pengembangan model hibrida yang mengintegrasikan *EfficientNet-B0* sebagai *feature extractor* dengan *Prototypical Network* sebagai *classifier* untuk klasifikasi multikelas DR menggunakan *dataset* APTOS 2019. Tujuan utamanya adalah mengevaluasi bagaimana integrasi *few-shot learning* dapat meningkatkan performa model baseline dalam menangani distribusi data yang tidak seimbang.

Penelitian sebelumnya dalam [16] mengembangkan pendekatan *ensemble deep learning* berbasis *EfficientNet* untuk diagnosis DR yang lebih akurat. Dengan menggabungkan beberapa varian *EfficientNet* melalui strategi voting ensemble, model ini mampu meningkatkan akurasi di atas 90% serta memperbaiki sensitivitas terhadap kelas minoritas. Hasil tersebut menunjukkan bahwa pendekatan *ensemble* dapat mengurangi kesalahan klasifikasi dan meningkatkan kestabilan performa antar kelas, sehingga menjadi dasar penting bagi pengembangan arsitektur yang lebih adaptif terhadap variasi tingkat keparahan DR.

Studi lain dalam [28] memperkenalkan *HDR-EfficientNet*, arsitektur yang dioptimalkan untuk klasifikasi gabungan *Hypertensive Retinopathy* dan DR. Model ini mengombinasikan optimisasi *hyperparameter* dan *data augmentation* untuk memperkuat kemampuan generalisasi pada *dataset* yang tidak seimbang. Dengan akurasi mencapai lebih dari 92%, penelitian ini menegaskan bahwa penyetelan arsitektur dan pemrosesan data memainkan peran krusial dalam peningkatan kinerja model *EfficientNet* di domain medis.

Penelitian selanjutnya dalam [17] berfokus pada penerapan *transfer learning* menggunakan *EfficientNetB0* dengan teknik augmentasi data untuk mengatasi masalah ketidakseimbangan kelas dalam klasifikasi tingkat keparahan DR. Dengan *dataset* dari *Kaggle* yang terbatas dan tidak seimbang, model ini berhasil mencapai akurasi rata-rata 85%. Studi ini memperluas pemahaman mengenai efektivitas transfer learning pada kondisi data minoritas, sekaligus menunjukkan efisiensi *EfficientNet* sebagai *backbone* ringan dengan performa kompetitif.

Studi dalam [29] mengusulkan *ensemble* model berbasis *EfficientNetV2* untuk menilai kualitas citra DR sebelum klasifikasi utama dilakukan. Tujuannya adalah memastikan hanya citra berkualitas tinggi yang digunakan dalam tahap diagnosis otomatis. Dengan akurasi 88,7%, model ini membuktikan bahwa integrasi modul *quality control* dapat meningkatkan reliabilitas hasil klasifikasi dan mengurangi kesalahan akibat citra yang buram atau tidak fokus.

Sementara itu, penelitian dalam [30] kemudian memperkenalkan *RA-EfficientNet* (*Residual Attention EfficientNet*), yang menambahkan mekanisme *attention* untuk mendeteksi area patologis penting pada citra retina. Dengan akurasi 91,2% dan *loss* sebesar 0,42, model ini mengungguli *EfficientNet* standar, khususnya dalam identifikasi lesi mikroskopis. Pendekatan ini menunjukkan bahwa integrasi *attention mechanism* dapat meningkatkan fokus model pada fitur yang relevan secara klinis.

Selanjutnya, pengembangan model hibrida CNN-RNN dalam [31] memperluas konsep *deep learning* untuk deteksi dini DR. Dengan lebih dari 35.000 citra retina dari *dataset Kaggle*, model ini mencapai akurasi 86,53%. Penelitian ini menambahkan dimensi temporal terhadap analisis citra medis, yang melengkapi pengembangan arsitektur *EfficientNet* dalam memahami urutan spasial dan temporal pada data visual.

Studi lain dalam [32] melakukan perbandingan antara CNN, *Vision Transformer* (ViT), dan model hibrida CNN–Transformer untuk klasifikasi DR. Hasil eksperimen menunjukkan hasil akurasi tertinggi sebesar 90,1% serta meningkatkan interpretabilitas hasil klasifikasi. Penelitian ini menegaskan

bahwa penggabungan arsitektur konvolusional dan *attention-based* dapat menghasilkan model yang lebih transparan dan akurat dalam konteks medis.

Sejalan dengan sebelumnya, penelitian dalam [33] juga mengembangkan model hibrida yang mengintegrasikan arsitektur berbasis CNN dan *Transformer*, yakni *EfficientNet* dan *Swin Transformer* untuk prediksi DR. Integrasi ini memungkinkan model memanfaatkan fitur lokal (*local features*) dari *EfficientNet* dan fitur global (*contextual features*) dari *Transformer*. Hasil evaluasi menunjukkan akurasi 97% dengan sensitivitas 0,95 dan spesifitas 0,98, menegaskan efektivitas kombinasi dua paradigma representasi fitur tersebut.

Penelitian dalam [34] memperkenalkan *DRNet* berbasis *Prototypical Network* untuk *few-shot classification* DR. Model ini memanfaatkan *episodic learning* dan *attention mechanism* untuk memperkuat representasi fitur antar kelas. Dengan akurasi 99,73% untuk deteksi DR dan 98,18% untuk grading, penelitian ini menunjukkan potensi besar *ProtoNet* dalam menangani keterbatasan data dan ketidakseimbangan kelas pada domain medis.

Studi dalam [26] kemudian mengembangkan *ProtoMed*, yaitu *Prototypical Network* dengan *auxiliary regularization* untuk klasifikasi citra medis berbasis *few-shot learning*. Pendekatan ini memperbaiki stabilitas dan generalisasi fitur pada *dataset* kecil, sekaligus meningkatkan akurasi model dalam mengenali kelas baru dengan jumlah data latih minimal.

Penelitian selanjutnya dalam [35] melanjutkan penelitian pada ranah segmentasi citra medis dengan mengusulkan metode *Few-Shot Medical Image Segmentation* menggunakan *high-fidelity prototypes*. Pendekatan ini menitikberatkan pada pembentukan prototipe berkualitas tinggi yang mampu mendukung segmentasi presisi tinggi. Hasil penelitian ini memperkuat efektivitas pendekatan berbasis *ProtoNet* untuk tugas-tugas medis yang kompleks seperti segmentasi jaringan.

Studi dalam [36] menerapkan *Prototypical Network* pada klasifikasi lesi kulit, menunjukkan kemampuannya mengenali berbagai tipe lesi meskipun jumlah data pelatihan terbatas. Hasil penelitian ini mempertegas keunggulan *few-shot learning* dalam mengatasi kelangkaan data, memperkuat dasar

pemikiran integrasi ProtoNet ke dalam tugas klasifikasi medis lainnya.

Penelitian dalam [37] memperkenalkan *Dual-Channel Prototype Network* untuk klasifikasi citra patologi. Model ini menggunakan dua saluran prototipe, yaitu saluran visual dan semantik, yang bekerja paralel untuk meningkatkan akurasi identifikasi jaringan patologis. Hasilnya menunjukkan peningkatan efisiensi komputasi sekaligus akurasi klasifikasi, menjadikannya salah satu pengembangan signifikan dari pendekatan *ProtoNet* klasik.

Sementara itu, studi dalam [38] mengembangkan algoritma *improved meta-learning* dan *transfer learning* untuk *few-shot medical image classification*. Model ini dirancang agar mampu mentransfer pengetahuan dari domain besar ke domain kecil, memperkuat kemampuan generalisasi lintas penyakit. Penelitian ini memperluas konsep *Prototypical Network* dengan fokus pada adaptasi cepat di berbagai domain medis.

Selain itu, penelitian dalam [18] mengombinasikan *DenseNet* dan VGG-CNN untuk deteksi serta klasifikasi DR. Pendekatan ini menunjukkan peningkatan signifikan dalam akurasi dan F1-score dibandingkan model tunggal. Hasil tersebut menegaskan potensi integrasi beberapa arsitektur CNN dalam meningkatkan ketepatan diagnosis otomatis berbasis citra fundus.

Studi dalam [39] menunjukkan bahwa penerapan *Deep Transfer Learning* berbasis jaringan konvolusional mampu mencapai efisiensi pelatihan tinggi dan konvergensi cepat bahkan pada *dataset* berkualitas rendah. Pendekatan ini memperluas penerapan teknik *transfer learning* di luar domain *Diabetic Retinopathy* (DR) dan memperkuat relevansi prinsip integrasi model hibrida pada berbagai aplikasi medis.

Dari berbagai penelitian terdahulu, terlihat tren peningkatan performa klasifikasi DR melalui pengembangan arsitektur *EfficientNet* yang dioptimalkan, penerapan model hibrida seperti *CNN–Transformer*, serta pemanfaatan *Prototypical Network* untuk mengatasi keterbatasan data pada *few-shot learning*. Pendekatan hibrida terbukti efektif mengekstraksi fitur kompleks dan memperkuat generalisasi model, sedangkan *ProtoNet* unggul dalam mengenali kelas dengan data terbatas. Kesenjangan penelitian yang ada terletak pada penerapan model hibrida *EfficientNet–Prototypical Network*

secara *end-to-end* pada data medis tidak seimbang. Penelitian ini berfokus pada integrasi *EfficientNet-B0* dan *Prototypical Network* untuk klasifikasi multikelas DR dengan pendekatan *few-shot learning* yang dilatih bersamaan guna mencapai keseimbangan performa antar kelas.

Tabel 2.1.1 Penelitian Terdahulu

No	Judul	Metode	Hasil Utama
1	<i>Ensemble Deep Learning Approach for Diabetic Retinopathy Classification Using EfficientNet</i> [16]	<i>Ensemble EfficientNet</i>	Akurasi di atas 90% dan meningkatkan sensitivitas kelas minor
2	<i>HDR-EfficientNet: Hybrid Deep Learning Model for Hypertensive Retinopathy and Diabetic Retinopathy</i> [28]	<i>Optimized EfficientNet dengan augmentasi</i>	Akurasi lebih dari 92%, performa lebih baik dibanding CNN konvensional
3	<i>EfficientNetB0 Transfer Learning for Severity Classification of Diabetic Retinopathy</i> [17]	<i>Transfer learning + data augmentation</i>	Akurasi rata-rata 85%, efektif menangani kelas minor
4	<i>EfficientNetV2-Based Ensemble Model for Pre-Diagnostic Image Quality Assessment in Diabetic Retinopathy</i> [29]	<i>Ensemble EfficientNetV2</i>	Akurasi 88,7%, menilai kualitas citra sebelum klasifikasi
5	<i>A Novel Few-Shot Classification Framework for Diabetic Retinopathy Detection and Grading</i> [34]	<i>Prototypical Network dengan episodic learning</i>	Akurasi 99,73%, deteksi grading 98,18%
6	<i>ProtoMed: Prototypical Network with Auxiliary Regularization for Few-Shot Medical Image Classification</i> [26]	<i>Prototypical Network few-shot</i>	Representasi fitur stabil, akurasi meningkat
7	<i>Dual-Channel Network for Few-Shot Pathology Image Classification</i> [37]	<i>Dual-channel Prototypical Network</i>	Akurasi 85,2 persen pada 10-shot dengan peningkatan 6,81 persen dibanding <i>ProtoNet</i>

No	Judul	Metode	Hasil Utama
8	<i>A Hybrid Neural Network Approach for Classifying Diabetic Retinopathy Subtypes [33]</i>	<i>Hybrid EfficientNet + Swin Transformer</i>	Akurasi 97%, sensitivitas 0,95, spesifisitas 0,98

2.2 *Diabetic Retinopathy (DR)*

Diabetic Retinopathy (DR) merupakan komplikasi mikroangiopati serius pada pasien diabetes mellitus yang menyebabkan kerusakan pada pembuluh darah retina dan berpotensi menimbulkan kebutaan permanen apabila tidak terdeteksi secara dini [1], [2]. Kondisi ini dipicu oleh hiperglikemia kronis yang mengakibatkan peningkatan permeabilitas vaskular, oklusi kapiler, serta proliferasi pembuluh darah baru yang abnormal pada retina [3]. Berdasarkan proyeksi global, jumlah penderita DR diperkirakan akan meningkat secara signifikan hingga tahun 2045 seiring dengan pertumbuhan populasi penderita diabetes di seluruh dunia [4], [5].

Secara klinis, DR dikategorikan menjadi lima tingkat keparahan yaitu *No DR*, *Mild Non-Proliferative DR (NPDR)*, *Moderate NPDR*, *Severe NPDR*, dan *Proliferative DR (PDR)* [6], [7]. Pada tahap awal, tanda-tanda yang muncul berupa mikroaneurisma kecil dan perdarahan ringan, sementara tahap proliferatif ditandai dengan neovaskularisasi yang dapat menyebabkan perdarahan vitreus atau ablati retina [3], [6]. Faktor-faktor seperti lamanya menderita diabetes, tekanan darah tinggi, kontrol glukosa yang buruk, dan dislipidemia menjadi pemicu utama yang mempercepat perkembangan penyakit ini [1], [5].

Proses diagnosis DR secara konvensional dilakukan oleh dokter spesialis mata melalui pemeriksaan citra fundus retina. Namun, metode manual ini memiliki keterbatasan karena rentan terhadap perbedaan subjektivitas antar pengamat serta membutuhkan waktu dan tenaga yang cukup besar, terutama untuk skrining dalam skala luas [8]. Tantangan lain muncul dari variasi kualitas citra fundus akibat pencahayaan, resolusi kamera, dan kondisi fisiologis pasien yang berbeda-beda, sehingga dapat memengaruhi akurasi penilaian [8].

Dalam konteks tersebut, pendekatan berbasis *Deep Learning* menjadi

solusi yang efektif karena mampu mengekstraksi fitur patologis secara otomatis dari citra retina dan melakukan klasifikasi tingkat keparahan penyakit dengan presisi tinggi [9], [10]. Model *Convolutional Neural Network* (CNN) seperti *ResNet*, *VGG*, dan *EfficientNet* telah menunjukkan kemampuan unggul dalam mendeteksi DR melalui pembelajaran representasi spasial dari citra retina [11]. Namun, sebagian besar penelitian masih terkendala pada ketidakseimbangan kelas dan keterbatasan data untuk kategori tertentu, yang sering menyebabkan performa klasifikasi menurun pada kelas minor.

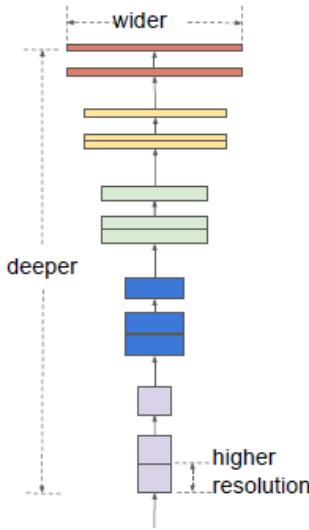
Oleh karena itu, penelitian ini berfokus pada pengembangan model hibrida yang mengintegrasikan *EfficientNet-B0* sebagai *feature extractor* dengan *Prototypical Network* sebagai *classifier* berbasis *few-shot learning* untuk mengatasi masalah ketidakseimbangan kelas dan keterbatasan data pelatihan. Pendekatan ini diharapkan dapat meningkatkan performa klasifikasi multikelas DR secara lebih seimbang dan efisien, serta memberikan kontribusi terhadap sistem diagnosis otomatis yang lebih andal dalam mendukung proses skrining dan pemantauan pasien diabetes.

2.3 *EfficientNet-B0*

Convolutional Neural Network (CNN) merupakan salah satu arsitektur *deep learning* yang paling banyak digunakan dalam klasifikasi citra medis karena kemampuannya mengekstraksi fitur spasial secara otomatis dari data gambar [11]. Namun, model CNN konvensional seperti *VGG*, *ResNet*, dan *DenseNet* sering kali memiliki jumlah parameter yang besar sehingga memerlukan sumber daya komputasi tinggi serta berisiko mengalami *overfitting* ketika diterapkan pada *dataset* medis yang terbatas. Tantangan ini mendorong pengembangan arsitektur yang lebih efisien tanpa mengorbankan performa, salah satunya adalah *EfficientNet*, yang dikembangkan untuk mencapai keseimbangan optimal antara akurasi dan efisiensi komputasi [13].

EfficientNet diperkenalkan dalam penelitian [14] sebagai pendekatan baru dalam *scaling* arsitektur jaringan yang disebut *compound scaling*. Pendekatan ini berbeda dengan model konvensional yang hanya meningkatkan kedalaman atau lebar jaringan secara tunggal, karena *EfficientNet* memperbesar

semua dimensi jaringan secara proporsional agar peningkatan performa tetap efisien [14]. Dengan *compound scaling*, peningkatan kapasitas model dilakukan secara terukur sehingga performa dapat meningkat tanpa menambah kompleksitas jaringan secara berlebihan. Konsep ini menekankan bahwa setiap dimensi model harus diperluas secara seimbang agar akurasi meningkat dengan efisiensi komputasi yang terjaga. Hubungan antara faktor kedalaman, lebar, dan resolusi divisualisasikan pada Gambar 2.3.1.



Gambar 2.3.1 *Compound Scaling*

Sumber: [14]

Secara matematis, hubungan tersebut dijelaskan dengan rumus *compound scaling* berikut:

$$depth = \alpha^\phi, width = \beta^\phi, resolution = \gamma^\phi$$

Dengan *constraint*:

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$$

$$\alpha, \beta, \gamma \geq 1$$

(2.1)

Keterangan:

α : konstanta faktor skala kedalaman (*depth*)

β : konstanta faktor skala lebar jaringan (*width*)

γ : konstanta faktor skala resolusi input (*resolution*)

ϕ : koefisien skala keseluruhan yang mengontrol kompleksitas model

Pendekatan matematis ini memungkinkan *EfficientNet* mencapai efisiensi tinggi dengan jumlah parameter yang jauh lebih sedikit dibandingkan arsitektur konvensional pada tingkat akurasi yang setara. Dengan kata lain, setiap kenaikan nilai ϕ meningkatkan semua dimensi jaringan secara proporsional, menghasilkan model yang lebih besar namun tetap efisien secara komputasi [14].

Arsitektur *EfficientNet* terdiri dari beberapa varian mulai dari B0 hingga B7, di mana setiap varian merupakan hasil *scaling* dari arsitektur dasar *EfficientNet-B0*. Varian B0 berfungsi sebagai *baseline* yang dirancang melalui optimisasi *Neural Architecture Search* (NAS) untuk memperoleh konfigurasi terbaik antara ukuran, kecepatan, dan akurasi [14]. Setiap varian berikutnya meningkatkan kedalaman, lebar, dan resolusi input secara proporsional berdasarkan rumus *compound scaling* yang telah dijelaskan sebelumnya.

Tabel 2.3.1 Varian EfficientNet

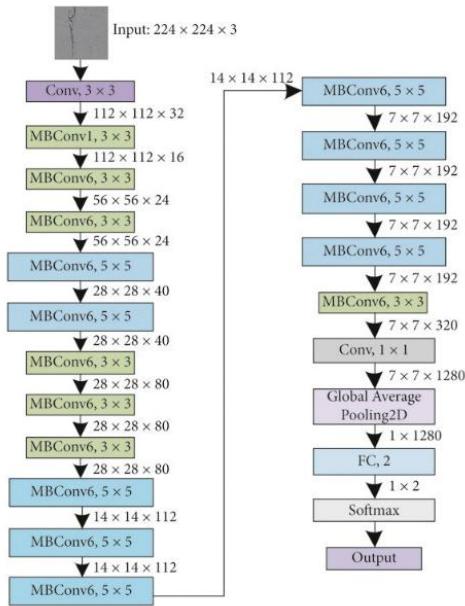
Varian	Depth (ϕ)	Resolusi Input	Jumlah Parameter (Juta)	Accuracy (%)	FLOPS (Billion)
B0	1.0	224×224	5.3	77.1	0.39
B1	1.1	240×240	7.8	79.1	0.70
B2	1.2	260×260	9.2	80.1	1.0
B3	1.4	300×300	12	81.6	1.8
B4	1.8	380×380	19	83.0	4.2
B5	2.2	456×456	30	83.6	9.9
B6	2.6	528×528	43	84.0	19.0

Sumber: [14]

Dari tabel 2.3.1 dapat dilihat bahwa peningkatan resolusi input dan kedalaman jaringan berbanding lurus dengan kenaikan akurasi, namun tetap menjaga efisiensi jumlah parameter. Varian B0 menjadi pilihan ideal untuk penelitian yang membutuhkan keseimbangan antara performa dan kebutuhan komputasi.

Secara struktural, *EfficientNet-B0* dibangun menggunakan blok utama *MBConv* (*Mobile Inverted Bottleneck Convolution*) yang diadaptasi dari arsitektur *MobileNetV2* [15]. Blok ini menggabungkan *depthwise separable*

convolution untuk mengurangi jumlah parameter sekaligus mempertahankan kemampuan ekstraksi fitur yang kuat. Di dalam setiap blok *MBConv* terdapat mekanisme *Squeeze-and-Excitation* yang berfungsi menyesuaikan bobot kanal berdasarkan informasi global, sehingga model dapat lebih fokus pada fitur penting dari citra retina. Proses aliran data dalam *EfficientNet-B0* secara umum digambarkan dalam Gambar 2.3.2 yang terdiri dari tahapan awal konvolusi, batch normalization, aktivasi *Swish*, blok *MBConv* berulang, dan lapisan klasifikasi akhir menggunakan *global average pooling* serta *fully connected layer*.



Gambar 2.3.2 Arsitektur *EfficientNet-B0*

Sumber: [40]

Dalam konteks penelitian ini, *EfficientNet-B0* digunakan sebagai *feature extractor* utama untuk mengekstraksi representasi fitur dari citra fundus retina. Pemilihan varian B0 didasarkan pada pertimbangan efisiensi komputasi dan stabilitas performa pada dataset berukuran sedang seperti APTOS 2019. Arsitektur ini memungkinkan peneliti memperoleh keseimbangan antara akurasi tinggi dan jumlah parameter yang ringan, menjadikannya ideal untuk implementasi pada sistem klasifikasi multikelas *Diabetic Retinopathy*.

Pendekatan ini juga memberikan dasar yang kuat bagi integrasi dengan *Prototypical Network* pada tahap selanjutnya, di mana representasi fitur yang

dihasilkan oleh *EfficientNet-B0* akan dimanfaatkan untuk pembelajaran berbasis *metric distance* dalam menghadapi masalah ketidakseimbangan kelas dan keterbatasan data pelatihan pada kasus *Diabetic Retinopathy*.

2.4 Prototypical Network

Pendekatan *few-shot learning* berkembang pesat sebagai solusi terhadap keterbatasan data pelatihan pada klasifikasi citra medis yang sering mengalami *class imbalance* dan jumlah sampel terbatas [21], [22]. Metode ini dirancang agar model mampu mengenali pola dari sejumlah kecil contoh setiap kelas, sehingga efektif diterapkan pada domain medis di mana anotasi data membutuhkan keahlian klinis tinggi. Salah satu metode paling berpengaruh dalam bidang ini adalah *Prototypical Network (ProtoNet)*, yang diperkenalkan dalam penelitian [23].

ProtoNet bekerja dengan membangun representasi setiap kelas dalam ruang embedding melalui perhitungan rata-rata fitur dari contoh-contoh dalam *support set*. Setiap kelas diwakili oleh satu vektor rata-rata yang disebut *prototype*, sedangkan proses klasifikasi dilakukan dengan membandingkan jarak antara *query sample* dan setiap *prototype* menggunakan metrik jarak, umumnya *Euclidean distance*. Berbeda dengan *convolutional classifier* konvensional yang membutuhkan pelatihan dengan data besar dan parameter banyak, *ProtoNet* mengandalkan pembelajaran berbasis jarak yang lebih efisien dan mampu beradaptasi dengan cepat terhadap kelas baru tanpa pelatihan ulang secara menyeluruh [24].

Pembentukan prototipe kelas dilakukan dengan menghitung *centroid* dari seluruh *embedding* sampel *support set* untuk setiap kelas. Prototipe ini merepresentasikan karakteristik umum dari masing-masing kelas dalam ruang embedding berdimensi tinggi. Secara matematis, prototipe kelas ke- k dapat diformulasikan sebagai berikut:

$$c_k = \left(\frac{1}{|S_k|} \right) \sum_{\{(x_i, y_i) \in S_k\}} f_{\phi(x_i)} \quad (2.2)$$

Keterangan:

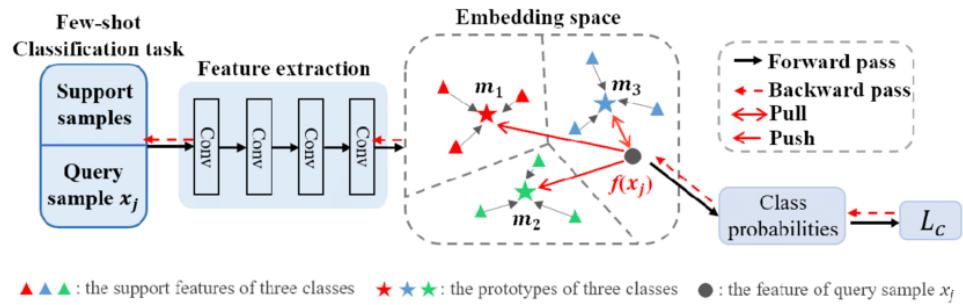
- c_k : prototipe kelas ke- k ,
- S_k : himpunan sampel *support* untuk kelas ke- k ,
- x_i : citra ke- i pada kelas ke- k
- y_i : label kelas citra x_i
- $f_{\phi(x_i)}$: hasil *embedding* citra x_i oleh *feature extractor*,
- ϕ : parameter *learnable* pada *feature extractor*.

Setelah prototipe terbentuk, tahap selanjutnya adalah klasifikasi *query sample* berdasarkan kedekatan jarak dalam ruang *embedding*. Proses ini dilakukan dengan menghitung probabilitas keanggotaan setiap *query sample* terhadap seluruh prototipe menggunakan jarak *Euclidean* sebagai *metric similarity*. Semakin kecil jarak antara *embedding query sample* dan prototipe suatu kelas, semakin tinggi probabilitas *query sample* tersebut termasuk ke dalam kelas yang bersangkutan. Perhitungan probabilitas ini menggunakan fungsi *softmax* atas negatif jarak *Euclidean* yang diformulasikan dalam penelitian [23] dan dapat dinyatakan dalam rumus berikut:

$$p_{\phi}(y = k|x) = \frac{\exp(-d(f_{\phi(x)}, c_k))}{\sum_{k'} \exp(-d(f_{\phi(x)}, c_{k'}))} \quad (2.3)$$

Keterangan:

- $p_{\phi}(y = k|x)$: probabilitas citra x termasuk kelas k ,
- x : citra *query* yang akan diklasifikasikan,
- $f_{\phi(x)}$: *embedding* citra *query*,
- c_k : prototipe kelas ke- k ,
- k' : indeks seluruh kelas pada *dataset*,
- $d(\cdot)$: fungsi jarak *Euclidean*,
- $\exp(\cdot)$: fungsi eksponensial untuk menghitung skor *softmax*,



Gambar 2.4.1 Arsitektur Prototypical Network

Sumber: [41]

Keunggulan utama *ProtoNet* terletak pada kemampuannya menghasilkan representasi yang stabil dan konsisten meskipun data terbatas. Dalam bidang medis, pendekatan ini telah berhasil diaplikasikan pada berbagai tugas seperti klasifikasi lesi kulit [36], segmentasi citra medis [35], dan klasifikasi patologi [37], yang masing-masing menunjukkan peningkatan akurasi signifikan dibandingkan metode berbasis *supervised learning* konvensional.

Dalam konteks penelitian ini, *Prototypical Network* dipilih sebagai *classifier* karena kemampuannya mengatasi ketidakseimbangan kelas dan keterbatasan jumlah sampel pada dataset APTOS 2019. Model ini akan diintegrasikan dengan *EfficientNet-B0* sebagai *feature extractor*, di mana fitur spasial yang dihasilkan oleh *EfficientNet* akan dimanfaatkan sebagai representasi *embedding* bagi *ProtoNet*. Sinergi kedua model ini diharapkan dapat menghasilkan sistem klasifikasi *Diabetic Retinopathy* yang efisien, adaptif, dan tetap akurat meskipun jumlah data terbatas.

2.5 Asia Pacific Tele-Ophthalmology Society (APROS) 2019 Dataset

Dataset APTOS 2019 *Blindness Detection* merupakan salah satu *dataset* publik paling banyak digunakan untuk penelitian klasifikasi *Diabetic Retinopathy* (DR) berbasis citra fundus retina. *Dataset* ini disediakan oleh *Asia Pacific Tele-Ophthalmology Society* (APROS) melalui *platform Kaggle* dan dirancang untuk mendukung pengembangan sistem *Computer-Aided Diagnosis* (CAD) dalam mendeteksi tingkat keparahan DR dari citra retina berwarna resolusi tinggi. Setiap citra diambil menggunakan kamera fundus dengan variasi

kondisi pencahayaan dan kualitas gambar yang merepresentasikan kasus nyata di klinik mata [27].

Secara kuantitatif, *dataset* APTOS 2019 terdiri atas 3.662 citra retina beranotasi tingkat keparahan DR yang diklasifikasikan menjadi lima kelas, yaitu *No DR* (0), *Mild* (1), *Moderate* (2), *Severe* (3), dan *Proliferative DR* (4). Anotasi dilakukan oleh dokter spesialis mata berdasarkan pedoman *International Clinical Diabetic Retinopathy* (ICDR). Proporsi kelas dalam *dataset* ini sangat tidak seimbang, di mana kelas *No DR* mencakup hampir separuh jumlah data, sedangkan kelas *Severe* dan *Proliferative DR* hanya memiliki persentase kecil, sebagaimana juga dilaporkan dalam penelitian [27], [34]. Kondisi ini menimbulkan tantangan signifikan bagi model pembelajaran mendalam karena dapat menyebabkan bias terhadap kelas mayoritas serta menurunkan kemampuan generalisasi model terhadap kasus langka [20]. Citra fundus dalam *dataset* ini menunjukkan variasi besar dalam hal resolusi, tingkat pencahayaan, fokus kamera, dan kondisi retina pasien, yang mencerminkan tantangan nyata dalam praktik klinis. Oleh karena itu, sebelum digunakan dalam proses pelatihan model, citra-citra tersebut perlu melalui tahap pra-pemrosesan untuk meningkatkan kualitas visual dan keseragaman data.

APTOS 2019 banyak digunakan dalam berbagai penelitian terkini karena menyediakan data berkualitas tinggi dengan kompleksitas visual yang bervariasi, sehingga ideal untuk menguji ketahanan dan generalisasi model *deep learning* terhadap variasi antar pasien. Beberapa studi berbasis *EfficientNet* dan *Prototypical Network* menggunakan *dataset* ini, seperti dalam [16], [34], yang menunjukkan peningkatan signifikan dalam akurasi dan stabilitas klasifikasi multikelas DR.

Berdasarkan batasan masalah yang telah ditetapkan, penelitian ini menggunakan APTOS 2019 karena *dataset* ini memiliki kompleksitas dan karakteristik distribusi kelas yang sesuai dengan tujuan pengembangan model hibrida. Ketidakseimbangan kelas dan keragaman kualitas citra menjadi tantangan yang ideal untuk mengevaluasi performa integrasi *EfficientNet-B0* sebagai *feature extractor* dan *Prototypical Network* sebagai *classifier* berbasis *few-shot learning*. Pendekatan ini diharapkan mampu menghasilkan sistem

klasifikasi yang lebih adaptif terhadap variasi data serta memberikan hasil yang lebih seimbang pada seluruh tingkat keparahan *Diabetic Retinopathy*.

2.6 Preprocessing

Pada tahap pengolahan citra medis, *preprocessing* memiliki peran penting dalam meningkatkan kualitas data sebelum memasuki tahap ekstraksi fitur dan klasifikasi. Proses ini bertujuan untuk mengurangi gangguan seperti variasi pencahayaan, artefak latar belakang, serta perbedaan warna yang dapat menurunkan performa model *deep learning*. Dalam konteks klasifikasi *Diabetic Retinopathy* (DR), preprocessing menjadi krusial karena citra fundus yang berasal dari berbagai perangkat kamera sering kali memiliki tingkat kecerahan dan kontras yang tidak seragam, sehingga diperlukan normalisasi visual agar model mampu mengekstraksi fitur patologis secara konsisten [16], [17].

Langkah-langkah *preprocessing* yang umum diterapkan meliputi pemotongan area retina agar fokus pada bagian yang relevan, penyesuaian kontras dan intensitas untuk memperjelas struktur vaskular, serta normalisasi piksel agar sesuai dengan kebutuhan arsitektur konvolusional seperti *EfficientNet-B0*. Proses ini berfungsi sebagai tahap penyelarasan visual sehingga setiap citra fundus memiliki representasi yang seragam sebelum masuk ke tahap pelatihan model klasifikasi.

2.6.1 Circle Crop

Circle crop merupakan teknik pemotongan citra retina berbasis *masking* yang mengisolasi area relevan berbentuk lingkaran untuk menghapus latar belakang gelap atau artefak di tepi gambar. Pendekatan serupa juga digunakan dalam metode *auto-cropping*, yang memotong area tidak informatif (*black border*) untuk meningkatkan fokus model terhadap fitur patologis retina seperti mikroaneurisma, eksudat, dan perdarahan [42]. Metode ini telah diterapkan secara efektif dalam penelitian [43], di mana *circle crop* digunakan untuk memastikan area input citra berada pada skala yang seragam sebelum melalui proses normalisasi dan *Enhanced Green*.

2.6.2 Enhanced Green

Enhanced Green merupakan teknik peningkatan citra fundus yang dikembangkan dari pendekatan Ramasubramanian, dengan fokus pada optimalisasi kanal hijau (*green channel*) untuk memperjelas fitur patologis pada retina. Metode ini bekerja dengan mengekstraksi kanal hijau citra RGB, kemudian menerapkan *Contrast Limited Adaptive Histogram Equalization* (CLAHE) untuk memperbaiki distribusi kontras lokal, dan dilanjutkan dengan *unsharp masking* guna menajamkan struktur halus seperti pembuluh darah dan mikroaneurisma. Pendekatan ini terbukti efektif dalam menonjolkan perbedaan antara jaringan retina normal dan area lesi yang menjadi indikator utama tingkat keparahan *Diabetic Retinopathy* (DR) [43].

Penelitian dalam [43] menunjukkan bahwa penerapan *Enhanced Green* pada dataset APTOS 2019 *Blindness Detection* menghasilkan performa klasifikasi terbaik dibandingkan metode Ben Graham, Nakhon, dan Ramasubramanian, dengan nilai akurasi mencapai 78,79%, *precision* 82,97%, *recall* 74,64%, dan AUC 95,81%. Hasil ini menunjukkan bahwa metode tersebut mampu menekan efek iluminasi yang tidak merata sekaligus meningkatkan keterbacaan fitur vaskular retina, sehingga citra yang dihasilkan menjadi lebih informatif bagi model *deep learning*. Oleh karena itu, *Enhanced Green* diadopsi dalam penelitian ini untuk memastikan konsistensi kualitas visual sebelum citra dimasukkan ke dalam arsitektur *EfficientNet-B0* untuk ekstraksi fitur yang lebih representatif.

2.7 Metrik Evaluasi Klasifikasi

Dalam penelitian klasifikasi citra medis, khususnya untuk *Diabetic Retinopathy* (DR), pemilihan metrik evaluasi yang tepat menjadi hal penting karena model tidak hanya dinilai dari akurasi keseluruhan tetapi juga dari kemampuannya mengenali tiap tingkat keparahan penyakit secara seimbang. Metrik-metrik ini berfungsi untuk menilai kinerja model *deep learning* dalam mengenali pola patologis pada citra retina serta menilai konsistensi prediksi terhadap label referensi medis [10], [20]. Ketidakseimbangan jumlah data antar kelas pada dataset DR menyebabkan metrik tunggal seperti akurasi tidak lagi

cukup representatif, sehingga diperlukan ukuran tambahan seperti *precision*, *recall*, *F1-score*, *macro-averaging*, dan *quadratic weighted kappa* untuk memberikan evaluasi yang lebih menyeluruh.

2.7.1 *Confusion Matrix*

Confusion matrix merupakan dasar dari seluruh metrik evaluasi yang digunakan dalam klasifikasi. Matriks ini menyajikan perbandingan antara label sebenarnya dengan hasil prediksi model, yang terdiri atas empat komponen utama yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) [11]. Struktur ini memudahkan analisis kesalahan model dan mengidentifikasi kecenderungan model dalam salah mengklasifikasikan data tertentu, terutama pada *dataset* medis yang bersifat tidak seimbang.

2.7.2 *Accuracy*

Accuracy merupakan rasio jumlah prediksi yang benar terhadap keseluruhan data yang diuji dan sering digunakan sebagai metrik awal untuk menilai performa model klasifikasi.

Rumus *Accuracy* dapat dituliskan sebagai:

$$Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)}$$
 (2.4)

Keterangan:

TP : prediksi positif yang benar,

TN : prediksi negatif yang benar,

FP : prediksi positif yang salah,

FN : prediksi negatif yang salah.

Meskipun akurasi memberikan gambaran umum, metrik ini dapat menyesatkan pada kasus dengan distribusi kelas yang tidak merata [10].

2.7.3 Precision

Precision digunakan untuk mengukur proporsi prediksi positif yang benar terhadap semua prediksi positif yang dibuat oleh model.

Rumus *precision* adalah:

$$Precision = \frac{TP_k}{(TP_k + FP_k)} \quad (2.5)$$

Keterangan:

TP_k : prediksi benar untuk kelas ke- k ,

FP_k : prediksi salah yang masuk ke kelas ke- k .

Nilai *precision* yang tinggi menunjukkan bahwa model jarang memberikan hasil positif palsu, yang sangat penting dalam sistem diagnosis medis agar tidak terjadi kesalahan klasifikasi pasien sehat sebagai penderita penyakit [10].

2.7.4 Recall

Recall atau sensitivitas, mengukur seberapa banyak data positif yang berhasil dideteksi oleh model dari seluruh data positif yang sebenarnya.

Rumus recall ditulis sebagai:

$$Recall = \frac{TP_k}{(TP_k + FN_k)} \quad (2.6)$$

Keterangan:

TP_k : prediksi benar untuk kelas ke- k ,

FN_k : sampel kelas ke- k yang gagal dikenali model.

Dalam konteks deteksi penyakit, *recall* memiliki arti klinis penting karena kesalahan pada prediksi negatif palsu (FN) dapat menyebabkan pasien yang sebenarnya sakit tidak terdeteksi [10].

2.7.5 *F1-Score*

F1-score merupakan ukuran harmonis antara *precision* dan *recall* yang digunakan untuk menyeimbangkan keduanya dalam situasi distribusi data yang tidak seimbang.

Rumus *F1-score* adalah:

$$F1 = 2 \times \frac{(Precision_k \times Recall_k)}{(Precision_k + Recall_k)} \quad (2.7)$$

Keterangan:

$Precision_k$: nilai presisi model,

$Recall_k$: nilai sensitivitas model.

Nilai F1 yang tinggi menunjukkan keseimbangan antara kemampuan model dalam mendekripsi kasus positif dan menghindari kesalahan klasifikasi [10].

2.7.6 *Macro-Averaging*

Macro-averaging digunakan untuk menghitung rata-rata dari setiap metrik (*precision*, *recall*, atau F1) pada seluruh kelas tanpa memperhitungkan jumlah data pada masing-masing kelas.

Rumusnya adalah:

$$Macro M = \frac{1}{K} \sum_{k=1}^K M_k \quad (2.8)$$

Keterangan:

M_k : nilai metrik kelas ke- k (*Precision*, *Recall*, *F1-score*, dll.),

K : jumlah kelas.

Pendekatan ini lebih adil untuk *dataset* yang tidak seimbang karena setiap kelas memiliki bobot yang sama dalam perhitungan akhir [20].

2.7.7 Quadratic Weighted Kappa (QWK)

Quadratic Weighted Kappa (QWK) digunakan untuk mengukur tingkat kesepakatan antara hasil prediksi model dan label yang diberikan oleh ahli medis. Berbeda dari akurasi biasa, QWK memberikan bobot yang lebih besar pada kesalahan klasifikasi yang lebih jauh dari label sebenarnya.

Rumus QWK adalah:

$$\kappa = 1 - \frac{(\sum_{i=1}^K \sum_{j=1}^K w_{ij} O_{ij})}{(\sum_{i=1}^K \sum_{j=1}^K w_{ij} E_{ij})} \quad (2.9)$$

Bobot Penalti:

$$w_{ij} = \frac{(i-j)^2}{(K-1)^2} \quad (2.10)$$

Matriks Observasi:

$$O_{ij} = \frac{C_{ij}}{N} \quad (2.11)$$

Matriks Ekspektasi:

$$E_{ij} = H_i \cdot P_j$$

Dengan:

$$\begin{aligned} H_{ij} &= \frac{\sum_j C_{ij}}{N} \\ P_{ij} &= \frac{\sum_i C_{ij}}{N} \end{aligned} \quad (2.12)$$

- κ : nilai *Quadratic Weighted Kappa*,
- i : indeks kelas aktual,
- j : indeks kelas prediksi,
- w_{ij} : bobot penalti berdasarkan jarak ordinal antar kelas,
- O_{ij} : proporsi observasi,
- E_{ij} : proporsi ekspektasi jika prediksi acak,
- C_{ij} : jumlah sampel aktual dan prediksi,

- H_i : probabilitas aktual kelas ke- i ,
 P_j : probabilitas prediksi kelas ke- j ,
 K : jumlah kelas,
 N : total sampel,

Nilai κ berada antara -1 hingga 1 , di mana nilai mendekati 1 menunjukkan kesepakatan sempurna antara model dan label referensi [44] serta [21].

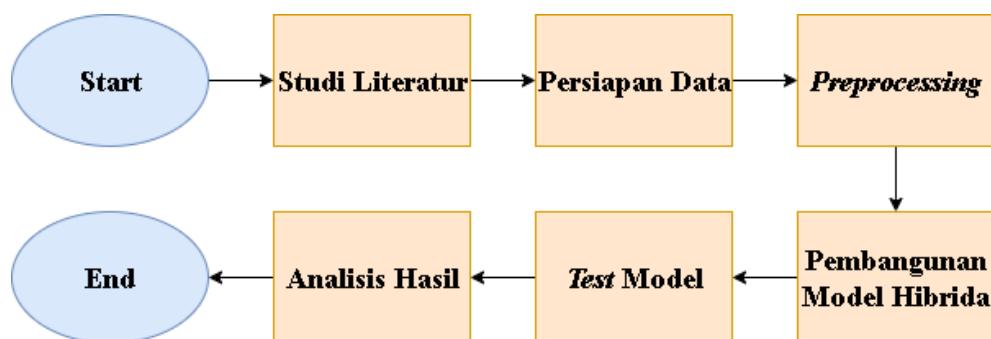
Metrik-metrik ini digunakan secara terpadu dalam penelitian untuk mengevaluasi performa model hibrida *EfficientNet Prototypical Network* pada klasifikasi multikelas *Diabetic Retinopathy*. Kombinasi berbagai metrik memungkinkan penilaian model secara menyeluruh, baik dari sisi akurasi keseluruhan maupun kemampuan mengenali kelas minoritas, sehingga hasil evaluasi lebih representatif terhadap performa nyata model pada kondisi klinis yang beragam.

BAB III

METODOLOGI

3.1 Tahapan Penelitian

Penelitian ini dilakukan melalui serangkaian tahapan sistematis yang dirancang untuk mencapai tujuan pengembangan model hibrida berbasis *EfficientNet-B0* dan *Prototypical Network* dalam klasifikasi tingkat keparahan *Diabetic Retinopathy* (DR) menggunakan *dataset* APTOS 2019. Secara umum seperti yang terlihat pada gambar 3.1.1, proses penelitian dimulai dari studi literatur guna memahami perkembangan terkini teknologi *deep learning* di bidang analisis citra medis, dilanjutkan dengan pengumpulan dan persiapan *dataset* yang meliputi analisis distribusi kelas serta pembagian data pelatihan dan pengujian. Tahap berikutnya adalah *preprocessing* citra retina yang mencakup *circle crop*, *enhanced green*, dan normalisasi ukuran citra agar sesuai dengan input arsitektur model. Setelah data siap, dilakukan pembangunan model hibrida dengan mengintegrasikan *EfficientNet-B0* sebagai *feature extractor* dan *Prototypical Network* sebagai *classifier* untuk menangani permasalahan ketidakseimbangan kelas dan keterbatasan data. Model yang dihasilkan kemudian dilatih dan diuji menggunakan metrik evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, serta *Quadratic Weighted Kappa* (QWK) untuk menilai performa secara menyeluruh. Hasil evaluasi selanjutnya dianalisis untuk mengidentifikasi pengaruh integrasi *Prototypical Network* terhadap peningkatan performa klasifikasi, terutama pada kelas minor dalam *dataset*.



Gambar 3.1.1 Tahapan Penelitian

3.2 Studi Literatur

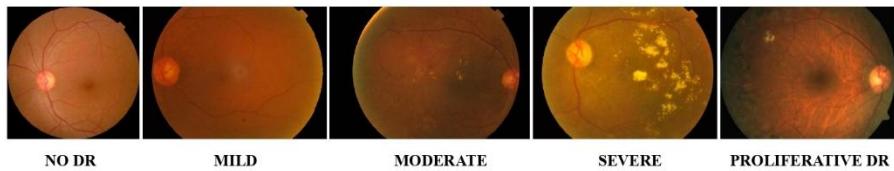
Dalam penelitian ini, studi literatur dilakukan dengan mengumpulkan berbagai referensi ilmiah yang relevan dan kredibel, meliputi jurnal internasional terindeks, prosiding konferensi, serta publikasi nasional bereputasi. Sumber-sumber tersebut digunakan untuk membangun dasar teoritis yang mendukung perancangan model hibrida berbasis *EfficientNet-B0* dan *Prototypical Network* dalam klasifikasi *Diabetic Retinopathy* (DR). Pemilihan literatur difokuskan pada publikasi dalam lima tahun terakhir agar informasi yang digunakan tetap mutakhir dan sesuai dengan perkembangan teknologi *deep learning* terkini. Setiap referensi yang dipilih memberikan kontribusi terhadap pemahaman konsep utama, seperti arsitektur CNN efisien, teknik *few-shot learning*, strategi *preprocessing* citra retina, serta metrik evaluasi kinerja model. Dengan demikian, studi literatur ini memastikan bahwa rancangan metodologi penelitian disusun berdasarkan pengetahuan yang valid, relevan, dan diakui secara akademik baik di tingkat nasional maupun internasional.

3.3 Persiapan Data

Tahap persiapan data merupakan fondasi utama dalam penelitian ini karena kualitas *dataset* sangat memengaruhi hasil pembelajaran model klasifikasi. Proses ini mencakup pemilihan sumber data, analisis distribusi kelas, serta pembagian data menjadi bagian pelatihan dan pengujian yang proporsional. Seluruh tahapan dirancang untuk memastikan bahwa model yang dikembangkan dapat belajar dari representasi citra retina yang bervariasi dan tetap mampu melakukan generalisasi terhadap data baru. *Dataset* yang digunakan dalam penelitian ini adalah APTOS 2019 *Blindness Detection* yang disediakan oleh *Asia Pacific Tele-Ophthalmology Society* (APROS) melalui platform *Kaggle* [44]. Dataset ini dipilih karena memiliki label tingkat keparahan *Diabetic Retinopathy* (DR) yang sesuai dengan standar *International Clinical Diabetic Retinopathy* (ICDR) dan telah digunakan secara luas dalam penelitian berbasis *deep learning* seperti yang dilaporkan dalam penelitian [19] yang mengevaluasi pengaruh peningkatan kualitas citra terhadap performa deteksi otomatis.

3.3.1 APTOS Dataset 2019

Dataset APTOS 2019 terdiri dari 3.662 citra retina berlabel lima tingkat keparahan *Diabetic Retinopathy* yaitu *No DR* (0), *Mild* (1), *Moderate* (2), *Severe* (3), dan *Proliferative DR* (4). Seluruh label ditetapkan oleh dokter spesialis mata berdasarkan pedoman ICDR untuk menjamin keakuratan anotasi. Citra dalam *dataset* ini diambil menggunakan berbagai jenis kamera fundus dengan resolusi tinggi, namun masih menunjukkan variasi pencahayaan dan kontras akibat perbedaan perangkat serta kondisi pencitraan. Variasi ini mencerminkan kondisi dunia nyata dalam praktik klinis seperti yang terlihat pada gambar 3.3.1 sehingga menjadikan *dataset* ini relevan untuk pengujian model klasifikasi berbasis *deep learning* [44].



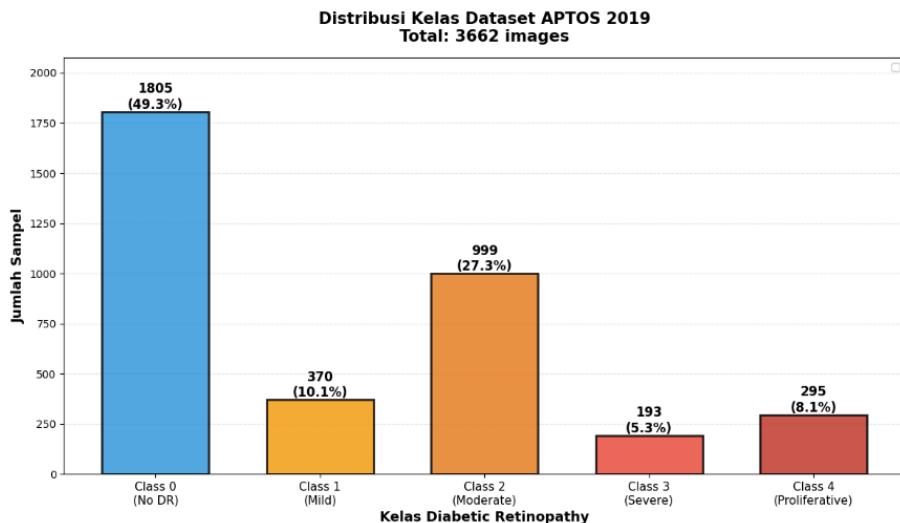
Gambar 3.3.1 Citra masing-masing kelas

Sumber: [44]

3.3.2 Analisis Distribusi Kelas

Analisis distribusi kelas dilakukan untuk memahami proporsi masing-masing kategori tingkat keparahan DR pada *dataset* APTOS 2019. Hasil analisis pada gambar 3.3.2 menunjukkan bahwa kelas No DR mendominasi dengan jumlah citra hampir mencapai separuh dari keseluruhan *dataset*, sementara kelas *Severe* dan *Proliferative DR* memiliki jumlah data yang relatif sedikit. Ketidakseimbangan ini menandakan adanya *masalah class imbalance* yang dapat menyebabkan bias model terhadap kelas mayoritas.

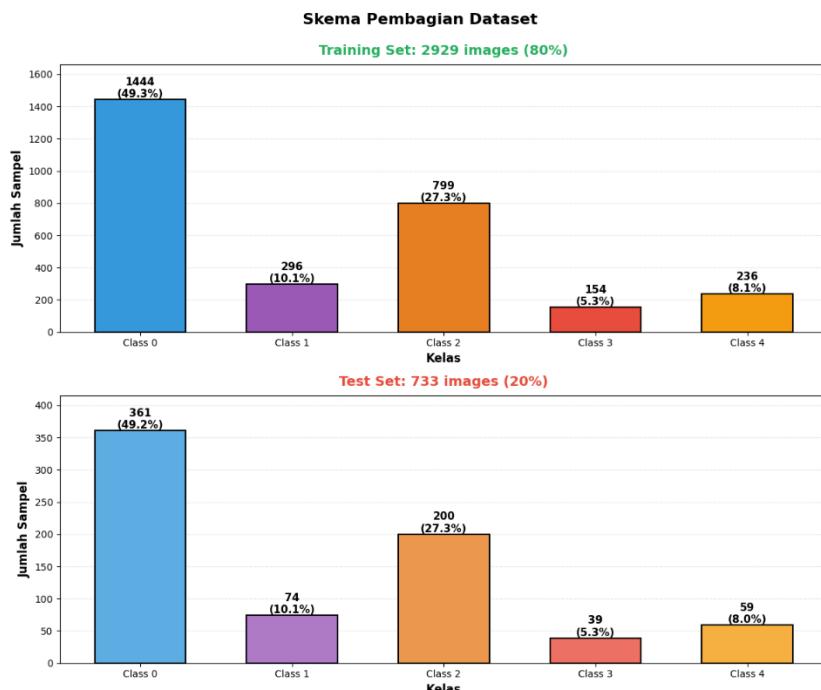
Penelitian dalam [20] menjelaskan bahwa ketidakseimbangan kelas merupakan tantangan umum dalam klasifikasi citra medis karena dapat mengurangi sensitivitas model terhadap kondisi langka. Pendekatan berbasis *few-shot learning* seperti *Prototypical Network* dinilai efektif dalam menghadapi permasalahan ini karena mampu mempelajari representasi fitur dari jumlah sampel terbatas sebagaimana dijelaskan dalam penelitian [21].



Gambar 3.3.2 Distribusi kelas Dataset APTOS 2019

3.3.3 Pembagian Data *Train* dan *Test*

Setelah distribusi kelas dianalisis, dataset dibagi menjadi dua *subset* utama yaitu *training set* dan *testing set* dengan rasio 80:20 menggunakan teknik stratifikasi agar proporsi tiap kelas tetap seimbang pada kedua *subset* seperti yang terlihat pada gambar 3.3.3. Strategi ini bertujuan untuk memastikan model memperoleh distribusi data yang representatif selama pelatihan sekaligus memungkinkan evaluasi yang adil pada data yang tidak terlihat sebelumnya.



Gambar 3.3.3 Skema pembagian Dataset

Penelitian dalam [16] menunjukkan bahwa pembagian data secara proporsional mampu meningkatkan stabilitas hasil klasifikasi *diabetic retinopathy* dengan mengurangi risiko *overfitting*. Pendekatan serupa diterapkan dalam penelitian ini untuk memastikan bahwa proses evaluasi performa model mencerminkan kemampuan generalisasi yang sebenarnya. Tahap pembagian data ini juga menjadi dasar bagi proses pelatihan model hibrida yang dijelaskan pada bagian selanjutnya.

3.4 Preprocessing

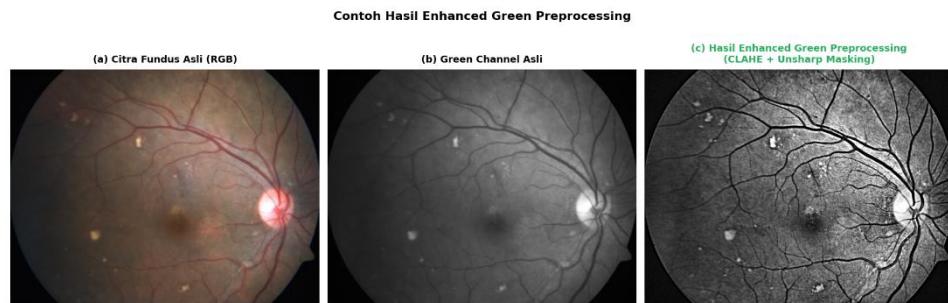
Tahap *preprocessing* dilakukan untuk meningkatkan kualitas citra retina sebelum masuk ke proses ekstraksi fitur oleh model *deep learning*. Citra fundus sering kali memiliki variasi pencahayaan, warna, serta artefak yang dapat menurunkan akurasi klasifikasi jika tidak dinormalisasi terlebih dahulu. Oleh karena itu, tahap ini berfungsi untuk menyelaraskan tampilan visual seluruh citra agar fitur patologis seperti mikroaneurisma, eksudat, dan perdarahan dapat terdeteksi secara optimal oleh model. Pendekatan *preprocessing* telah banyak digunakan dalam penelitian klasifikasi *Diabetic Retinopathy* karena terbukti mampu meningkatkan akurasi dan stabilitas hasil klasifikasi [19].

3.4.1 Circle Crop

Circle crop digunakan untuk mengisolasi area retina dari latar belakang gelap dan menghapus bagian tepi yang tidak relevan pada citra fundus. Teknik ini dilakukan dengan mendeteksi area melingkar retina kemudian memotong citra mengikuti batas tersebut, sementara area di luar lingkaran diisi dengan piksel hitam. Langkah ini memastikan bahwa model fokus hanya pada informasi patologis yang terdapat di dalam retina, seperti pembuluh darah dan lesi, tanpa gangguan dari artefak pencitraan. Pendekatan serupa diterapkan dalam penelitian [12] yang menunjukkan peningkatan performa deteksi DR setelah dilakukan pembersihan latar belakang melalui pemangkasan area non-retina.

3.4.2 Enhanced Green

Enhanced Green merupakan teknik peningkatan kualitas citra yang menitikberatkan pada optimalisasi kanal hijau (*green channel*) untuk memperjelas struktur vaskular dan lesi pada retina. Metode ini mengadaptasi pendekatan dari Ramasubramanian yang kemudian dikembangkan lebih lanjut oleh Widyaya dengan mengombinasikan ekstraksi kanal hijau, *Contrast Limited Adaptive Histogram Equalization* (CLAHE), serta *unsharp masking* untuk memperkuat detail lokal [43]. Pada gambar 3.4.1, terlihat bahwa Enhanced Green ini efektif karena kanal tersebut memiliki rasio kontras tertinggi antara pembuluh darah dan jaringan retina, sehingga meningkatkan ketajaman fitur yang digunakan oleh model klasifikasi.



Gambar 3.4.1 Contoh Hasil *Enhanced Green*

3.4.3 Normalisasi dan *Resize*

Langkah normalisasi dilakukan dengan menyesuaikan distribusi intensitas piksel agar memiliki rata-rata 0,5 dan deviasi standar 0,5 sebagaimana diterapkan dalam penelitian [39]. Pendekatan ini secara efektif menempatkan nilai piksel dalam rentang terstandarisasi (sekitar $[-1, 1]$), sehingga mempercepat konvergensi dan menjaga kestabilan pelatihan model. Setelah itu, proses *resize* dilakukan untuk menyesuaikan resolusi citra menjadi 224×224 piksel agar kompatibel dengan arsitektur *EfficientNet-B0* yang digunakan sebagai *feature extractor* [14].

3.5 Pembangunan Model Hibrida

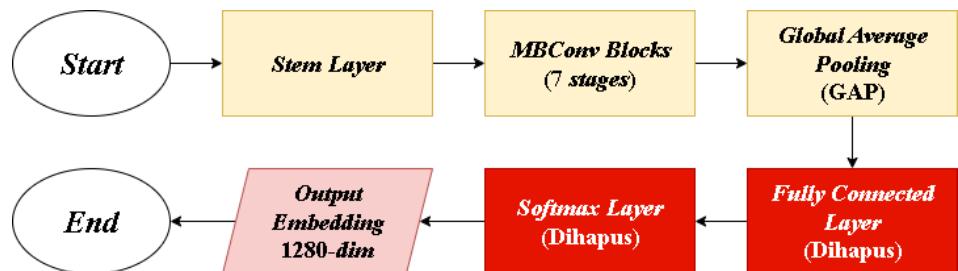
Penelitian ini membangun model hibrida dengan mengombinasikan *EfficientNet-B0* sebagai *feature extractor* dan *Prototypical Network* sebagai

classifier untuk meningkatkan akurasi klasifikasi tingkat keparahan *Diabetic Retinopathy* (DR) pada *dataset APTOS 2019*. Integrasi kedua metode ini dipilih karena karakteristiknya yang saling melengkapi, di mana *EfficientNet-B0* mampu mengekstraksi representasi spasial citra retina secara efisien, sementara *Prototypical Network* unggul dalam klasifikasi berbasis jarak yang efektif pada kondisi *class imbalance* dan jumlah data terbatas [21].

3.5.1 *EfficientNet-B0* sebagai *Feature Extractor*

Pada tahap ini, *EfficientNet-B0* berfungsi sebagai *feature extractor* utama yang menghasilkan representasi fitur berdimensi tetap dari citra retina yang telah melalui tahap *preprocessing*. Seperti ditunjukkan pada Gambar 3.5.1, proses ekstraksi dimulai dari input citra berukuran $224 \times 224 \times 3$ piksel yang masuk ke *Stem Layer*, yaitu lapisan konvolusi awal yang menyesuaikan intensitas serta skala spasial citra agar sesuai dengan arsitektur jaringan. Selanjutnya, fitur yang dihasilkan diproses melalui rangkaian *MBConv Blocks* (1–7) yang terdiri atas *depthwise separable convolution* dan *inverted residual bottleneck* untuk mengekstraksi pola vaskular dan lesi retina secara bertingkat tanpa meningkatkan kompleksitas komputasi.

Setelah seluruh blok selesai, hasilnya diringkas melalui *Global Average Pooling* (GAP) guna mereduksi dimensi spasial sambil mempertahankan informasi global dari citra retina. Lapisan *Fully Connected* dan *Softmax* asli pada *EfficientNet-B0* dihapus karena fungsi klasifikasinya akan digantikan oleh *Prototypical Network*, sehingga keluaran model berupa vektor *embedding* berdimensi 1280 yang merepresentasikan fitur citra retina secara padat.



Gambar 3.5.1 Alur *Feature Extraction* untuk *EfficientNet-B0*

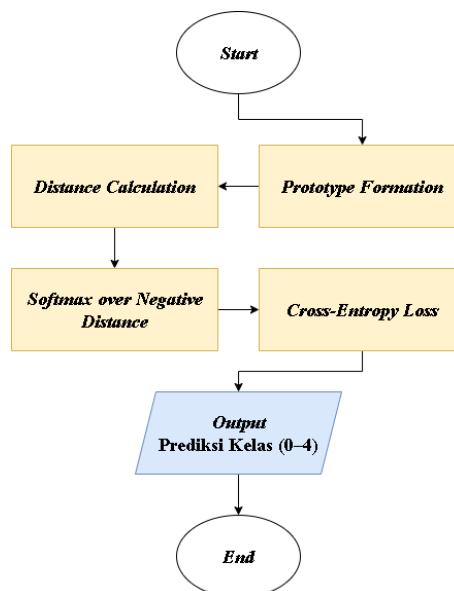
Bobot awal *EfficientNet-B0* diinisialisasi menggunakan *pretrained weights* dari *ImageNet* agar mempercepat konvergensi serta meningkatkan

generalisasi terhadap variasi data medis. Vektor *embedding* yang dihasilkan inilah yang selanjutnya akan diteruskan ke modul *Prototypical Network* untuk tahap klasifikasi pada Gambar 3.5.2.

3.5.2 *Prototypical Network* sebagai *Classifier*

Tahap ini menggunakan *Prototypical Network* sebagai *classifier* yang bekerja berdasarkan kedekatan jarak antara *embedding* hasil ekstraksi fitur dengan representasi prototipe tiap kelas. Seperti terlihat pada Gambar 3.5.2, proses diawali dengan *input embedding* berdimensi 1280 yang dihasilkan oleh *EfficientNet-B0*. Langkah pertama yaitu pembentukan prototipe kelas, di mana setiap kelas direpresentasikan oleh vektor rata-rata dari *embedding* seluruh sampel yang termasuk ke dalam kelas tersebut. Langkah ini memungkinkan model membentuk representasi pusat (*centroid*) yang menggambarkan karakteristik umum dari tiap kelas.

Tahap berikutnya adalah perhitungan jarak antara *embedding* citra uji dan masing-masing prototipe menggunakan metrik *Euclidean* untuk mengukur seberapa dekat representasi citra dengan tiap kelas. Nilai jarak yang dihasilkan kemudian dikonversi menjadi probabilitas kelas menggunakan fungsi *softmax* berbasis jarak negatif, sehingga kelas dengan jarak paling kecil memperoleh probabilitas prediksi tertinggi.



Gambar 3.5.2 Alur *Classifier* untuk *Prototypical Network*

Langkah selanjutnya adalah perhitungan *loss* menggunakan fungsi *cross-entropy* antara probabilitas hasil *softmax* dengan label sebenarnya. Proses ini mengarahkan pembelajaran agar *embedding* dari kelas yang sama menjadi lebih berdekatan, sementara *embedding* antar kelas semakin terpisah.

3.5.3 Integrasi Hibrida *EfficientNet-B0 & Prototypical Network*

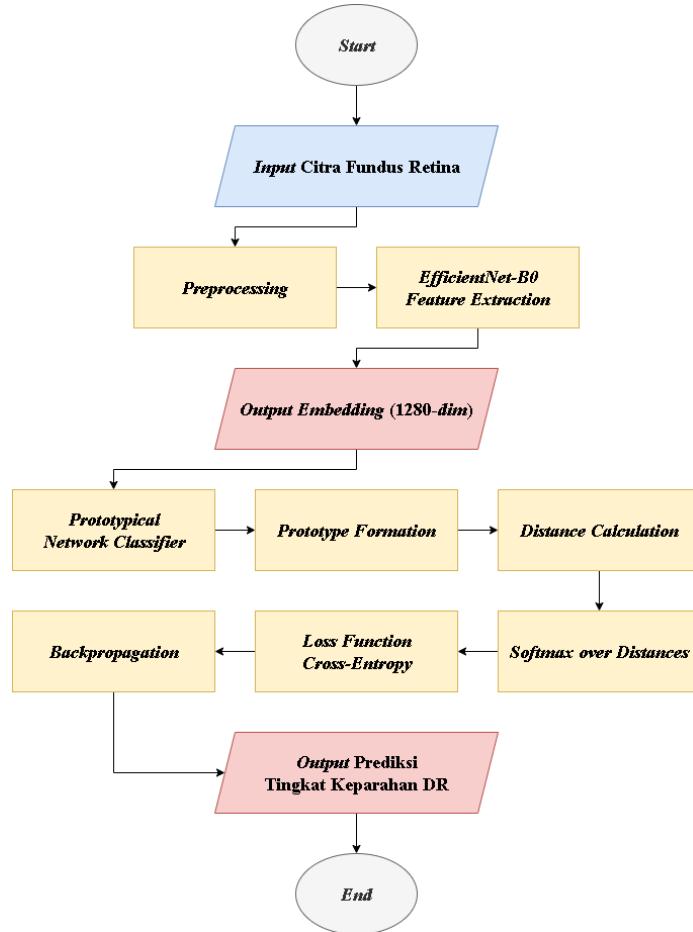
Tahap ini merupakan proses integrasi *end-to-end* antara *EfficientNet-B0* dan *Prototypical Network* yang berfungsi sebagai inti dari model hibrida klasifikasi *Diabetic Retinopathy*. Seperti ditunjukkan pada Gambar 3.5.3, alur dimulai dari *input* citra fundus retina yang telah melalui tahap *preprocessing*, meliputi *circle crop* untuk memfokuskan area retina, penyesuaian pencahayaan dan kontras menggunakan metode *Enhanced Green*, serta normalisasi dan pengubahan ukuran citra menjadi 224×224 piksel agar sesuai dengan kebutuhan arsitektur model.

Citra hasil *preprocessing* kemudian dimasukkan ke dalam *EfficientNet-B0* yang berperan sebagai *feature extractor* utama. Lapisan awal (*stem layer*) melakukan konvolusi awal dengan aktivasi *Swish* untuk menangkap pola dasar, diikuti oleh tujuh blok *MBConv* yang menggabungkan *depthwise convolution* dan *squeeze-and-excitation* guna memperkuat representasi struktural pembuluh darah retina. Setelah melalui seluruh blok, hasil *feature map* dirata-ratakan melalui *Global Average Pooling* (GAP) sehingga menghasilkan *embedding* berdimensi tetap sebesar 1280. Lapisan *fully connected* dan *softmax* bawaan *EfficientNet-B0* dihapus karena fungsi klasifikasi akan digantikan oleh *Prototypical Network*.

Embedding yang dihasilkan kemudian diteruskan ke modul *Prototypical Network*, yang membentuk *prototype* tiap kelas dengan menghitung rata-rata *embedding* seluruh citra dalam kelas yang sama. Jarak antara *embedding* citra dan setiap prototipe dihitung menggunakan metrik *Euclidean*, lalu hasilnya dikonversi menjadi probabilitas kelas melalui fungsi *softmax* berbasis jarak negatif.

Selama proses pelatihan, dilakukan *backpropagation* dari fungsi *loss* berbasis *cross-entropy* terhadap jarak antar *embedding*, sehingga gradien

kesalahan dari *Prototypical Network* mengalir kembali ke *EfficientNet-B0*. Mekanisme ini memungkinkan pembaruan bobot secara *end-to-end*, di mana *extractor* belajar menyesuaikan representasi fitur agar lebih terpisah antar kelas. Setelah proses optimisasi selesai, sistem menghasilkan output prediksi tingkat keparahan DR (kelas 0–4) berdasarkan prototipe dengan jarak terpendek terhadap *embedding* citra masukan.



Gambar 3.5.3 Alur Hibrida

3.6 Train dan Test Model

Tahap ini menjelaskan prosedur pelatihan dan pengujian model hibrida *EfficientNet-B0* dan *Prototypical Network* pada dataset APTOS 2019. Proses pelatihan dilakukan setelah seluruh citra retina melalui tahap *preprocessing*, sedangkan pengujian digunakan untuk mengevaluasi kemampuan generalisasi model terhadap data baru.

3.6.1 Proses *Train Model*

Pelatihan model dilakukan secara *end-to-end* dengan melewatkkan citra hasil *preprocessing* ke dalam *EfficientNet-B0* untuk menghasilkan representasi fitur berdimensi 1280. Vektor fitur ini kemudian diteruskan ke modul *Prototypical Network* yang berfungsi sebagai *classifier* berbasis jarak untuk menghitung kedekatan antara *embedding* setiap sampel dengan representasi pusat (*prototype*) masing-masing kelas yang diperoleh selama proses pelatihan. Jarak antar *embedding* dan *prototipe* dihitung menggunakan metrik *Euclidean*, dan nilai *loss* diperoleh melalui fungsi *cross-entropy* terhadap probabilitas hasil *softmax* berdasarkan jarak tersebut

Selanjutnya, proses *backpropagation* digunakan untuk memperbarui bobot pada *feature extractor* sesuai *gradien error* yang dihasilkan. Optimisasi dilakukan menggunakan algoritma Adam karena kemampuannya dalam menyesuaikan laju pembelajaran adaptif pada setiap parameter [14]. Nilai *learning rate* ditetapkan sebesar 1e-4 dengan *batch size* 32 dan *epoch* 50, yang diperoleh berdasarkan pengujian awal terhadap stabilitas konvergensi model.

Nilai *learning rate* sebesar 1e-4 dipilih karena secara empiris memberikan keseimbangan antara kecepatan konvergensi dan kestabilan pembaruan bobot. Jika nilai *learning rate* terlalu besar, gradien dapat menyebabkan model melompat-lompat di sekitar minimum global (*divergence*), sedangkan nilai yang terlalu kecil membuat proses pelatihan menjadi sangat lambat dan berisiko terjebak di *local minima*. Nilai 1e-4 merupakan standar yang umum digunakan pada optimisasi berbasis Adam, sesuai dengan rekomendasi dalam penelitian [45], yang menunjukkan bahwa Adam menghasilkan pembaruan bobot yang stabil dengan langkah pembaruan terbatas oleh parameter α . Selain mengacu pada literatur terdahulu, akan dilakukan eksperimen pendukung berskala kecil untuk memastikan kestabilan nilai learning rate tersebut terhadap karakteristik dataset APTOS 2019, namun eksperimen ini bersifat komplementer dan tidak menjadi fokus utama penelitian.

Pemilihan *batch size* 32 didasarkan pada kompromi antara efisiensi komputasi dan kestabilan estimasi gradien. Ukuran ini cukup besar untuk

memanfaatkan paralelisasi GPU, namun masih memungkinkan *generalization* yang baik tanpa *overfitting*, sebagaimana disarankan dalam penelitian [46] yang menjelaskan bahwa ukuran mini-batch kecil hingga menengah dapat membantu menjaga keseimbangan antara bias dan variansi dalam estimasi gradien. Jumlah *epoch* sebanyak 50 ditetapkan mengacu pada praktik umum pelatihan model *transfer learning* dengan arsitektur *EfficientNet*, yang umumnya mencapai konvergensi stabil dalam 40–50 epoch [14].

Untuk mengatasi ketidakseimbangan kelas dalam *dataset APTOS 2019*, dilakukan penyesuaian bobot kelas (*class weighting*) pada perhitungan *loss* agar kelas minor memiliki kontribusi lebih besar dalam proses pembaruan parameter [20]. Model terbaik ditentukan menggunakan strategi *early stopping* berdasarkan peningkatan nilai *validation accuracy* dan *Quadratic Weighted Kappa* (QWK).

3.6.2 Metrik Evaluasi

Evaluasi performa model dilakukan menggunakan beberapa metrik yang umum diterapkan dalam klasifikasi citra medis, yaitu *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan *Quadratic Weighted Kappa* (QWK). Pemilihan metrik ini didasarkan pada kebutuhan untuk menilai performa model secara menyeluruh terhadap distribusi kelas yang tidak seimbang, yang menjadi karakteristik khas pada *dataset Diabetic Retinopathy* seperti APTOS 2019 [20].

Accuracy digunakan untuk mengukur proporsi prediksi benar terhadap total data uji, sedangkan *Precision* dan *Recall* digunakan untuk menilai kemampuan model dalam mengenali kelas minor dan mencegah kesalahan klasifikasi antar tingkat keparahan. Kombinasi keduanya dirangkum melalui *F1-Score*, yang memberikan keseimbangan antara nilai *Precision* dan *Recall* pada kondisi distribusi data tidak merata [9].

Selain itu, *Quadratic Weighted Kappa* (QWK) diterapkan untuk mengevaluasi kesesuaian prediksi model terhadap anotasi dokter mata dengan mempertimbangkan jarak kesalahan antar kelas. QWK banyak digunakan pada penelitian-penelitian klasifikasi *Diabetic Retinopathy* karena mampu memberikan representasi performa yang lebih adil pada data bertipe ordinal, di

mana kesalahan antar kelas yang berdekatan tidak diberi penalti seberat kesalahan antar kelas yang jauh [16].

3.6.3 Model Pembanding (*Baseline*)

Untuk memastikan bahwa peningkatan performa yang diperoleh dari model hibrida tidak semata-mata disebabkan oleh faktor eksternal seperti *preprocessing* atau arsitektur *backbone*, penelitian ini menyertakan empat konfigurasi model pembanding (*baseline*). Tujuan utamanya adalah mengevaluasi kontribusi masing-masing komponen terhadap hasil klasifikasi.

Model pertama menggunakan *EfficientNet-B0* dengan arsitektur asli, di mana lapisan *fully connected* dan *softmax* digunakan untuk klasifikasi multikelas tanpa tahapan *preprocessing*. Model ini berfungsi sebagai *baseline* paling sederhana yang merepresentasikan performa murni *backbone* tanpa penyesuaian citra. Model kedua merupakan varian serupa namun dilengkapi tahapan *preprocessing* (*circle crop*, *enhanced green*, normalisasi) agar dapat mengukur sejauh mana peningkatan kualitas citra berpengaruh terhadap akurasi klasifikasi pada *backbone* yang sama.

Model ketiga adalah *Prototypical Network* berbasis CNN konvensional tanpa *preprocessing*, di mana *embedding* diperoleh melalui serangkaian lapisan konvolusi, *pooling*, dan *flatten* sebelum dihitung jarak antar kelas menggunakan metrik *Euclidean*. Konfigurasi ini menilai kemampuan *metric learning* murni tanpa pengaruh peningkatan kualitas citra. Model keempat merupakan *Prototypical Network* dengan *preprocessing* yang sama seperti eksperimen utama untuk mengidentifikasi interaksi antara *preprocessing* dan mekanisme pembelajaran berbasis jarak terhadap stabilitas representasi kelas minoritas.

Hasil keempat *baseline* tersebut akan dibandingkan secara kuantitatif menggunakan metrik yang sama seperti pada model hibrida, yaitu *accuracy*, *precision*, *recall*, *F1-score*, dan *Quadratic Weighted Kappa* (QWK). Selain itu, perbandingan visual terhadap *confusion matrix* juga akan digunakan untuk menunjukkan perubahan pola klasifikasi antar kelas. Analisis perbedaan kinerja antar model akan dibahas secara rinci pada subbab 3.6.4 Analisis Pengaruh Integrasi *Prototypical Network*.

3.6.4 Analisis Hasil

Tahap analisis hasil dirancang untuk mengevaluasi serta menafsirkan performa model berdasarkan metrik kuantitatif dan observasi kualitatif yang diperoleh dari seluruh konfigurasi percobaan, baik *baseline* maupun model hibrida. Tujuan utama dari tahap ini bukan hanya menilai tingkat akurasi model, tetapi juga memahami alasan di balik perubahan performa yang terjadi pada tiap skenario pengujian.

Analisis kuantitatif akan mencakup perbandingan nilai *accuracy*, *precision*, *recall*, *F1-score*, dan *Quadratic Weighted Kappa* (QWK) antar model, termasuk model *baseline* tanpa *preprocessing* dan model hibrida dengan *preprocessing*. Perbandingan ini akan digunakan untuk mengidentifikasi sejauh mana integrasi *Prototypical Network* dan tahapan *preprocessing* berpengaruh terhadap keseimbangan performa pada kelas mayoritas dan minoritas.

Analisis kualitatif akan difokuskan pada interpretasi *confusion matrix*, visualisasi distribusi *embedding*, serta contoh hasil prediksi yang salah (*misclassification analysis*). Jika ditemukan peningkatan performa, analisis akan difokuskan pada identifikasi faktor penyebab keberhasilan, seperti peningkatan representasi fitur atau efisiensi klasifikasi berbasis jarak. Sebaliknya, bila hasil menunjukkan kegagalan atau peningkatan tidak signifikan, pembahasan akan diarahkan pada kemungkinan penyebabnya, misalnya ketidakseimbangan data, *noise* pada citra, atau keterbatasan generalisasi *embedding*.

Visualisasi hasil hanya akan digunakan sebagai bukti pendukung ketika terdapat perubahan signifikan, seperti pergeseran distribusi prediksi, peningkatan nilai metrik tertentu, atau perubahan pola klasifikasi yang relevan untuk dijelaskan secara ilmiah. Analisis ini diharapkan dapat memberikan pemahaman menyeluruh mengenai perilaku model dan menjadi dasar bagi pembahasan pada bab selanjutnya mengenai efektivitas dan keterbatasan pendekatan hibrida yang diusulkan.

BAB IV
HASIL DAN PEMBAHASAN
BAB V
KESIMPULAN DAN SARAN

DAFTAR PUSTAKA

- [1] R. Singh, A. Walia, J. Kaur, P. Kumar, I. Verma, and N. Rani, "Diabetic Retinopathy - Pathophysiology to Treatment: A Review," *Curr Diabetes Rev*, vol. 21, no. 3, Mar. 2025, doi: 10.2174/0115733998259940231105200251.
- [2] M. Kropp *et al.*, "Diabetic retinopathy as the leading cause of blindness and early predictor of cascading complications—risks and mitigation," *EPMA Journal*, vol. 14, no. 1, pp. 21–42, Feb. 2023, doi: 10.1007/s13167-023-00314-8.
- [3] D. D. Chong, N. Das, and R. P. Singh, "Diabetic retinopathy: Screening, prevention, and treatment," *Cleve Clin J Med*, vol. 91, no. 8, pp. 503–510, Aug. 2024, doi: 10.3949/ccjm.91a.24028.
- [4] Z. L. Teo *et al.*, "Global Prevalence of Diabetic Retinopathy and Projection of Burden through 2045," *Ophthalmology*, vol. 128, no. 11, pp. 1580–1591, Nov. 2021, doi: 10.1016/j.ophtha.2021.04.027.
- [5] B. L. VanderBeek, Y. Yu, S. Cardillo, and R. Hubbard, "Twenty-Year Trends in Prevalence and Incidence of Diabetic Retinal Disease," *Ophthalmology*, vol. 132, no. 7, pp. 767–774, Jul. 2025, doi: 10.1016/j.ophtha.2025.01.022.
- [6] Z. Yang, T.-E. Tan, Y. Shao, T. Y. Wong, and X. Li, "Classification of diabetic retinopathy: Past, present and future," *Front Endocrinol (Lausanne)*, vol. 13, Dec. 2022, doi: 10.3389/fendo.2022.1079217.
- [7] C. J. Flaxel *et al.*, "Diabetic Retinopathy Preferred Practice Pattern®," *Ophthalmology*, vol. 127, no. 1, pp. P66–P145, Jan. 2020, doi: 10.1016/j.ophtha.2019.09.025.
- [8] S. Srinivasan *et al.*, "Inter-observer agreement in grading severity of diabetic retinopathy in wide-field fundus photographs," *Eye*, vol. 37, no. 6, pp. 1231–1235, Apr. 2023, doi: 10.1038/s41433-022-02107-1.
- [9] Y. A. Kadhim, M. U. Khan, and A. Mishra, "Deep Learning-Based Computer-Aided Diagnosis (CAD): Applications for Medical Image Datasets," *Sensors*, vol. 22, no. 22, p. 8999, Nov. 2022, doi: 10.3390/s22228999.
- [10] S. K. Zhou *et al.*, "A Review of Deep Learning in Medical Imaging: Imaging Traits, Technology Trends, Case Studies With Progress Highlights, and Future Promises," *Proceedings of the IEEE*, vol. 109, no. 5, pp. 820–838, May 2021, doi: 10.1109/JPROC.2021.3054390.
- [11] L. Alzubaidi *et al.*, "Review of deep learning: concepts, CNN architectures, challenges, applications, future directions," *J Big Data*, vol. 8, no. 1, p. 53, Mar. 2021, doi: 10.1186/s40537-021-00444-8.
- [12] C. Suedumrong, S. Phongmoo, T. Akarajaka, and K. Leksakul, "Diabetic Retinopathy Detection Using Convolutional Neural Networks with Background Removal, and Data Augmentation," *Applied Sciences*, vol. 14, no. 19, p. 8823, Sep. 2024, doi: 10.3390/app14198823.
- [13] P. Jeevan and A. Sethi, "Which Backbone to Use: A Resource-efficient Domain Specific Comparison for Computer Vision," Mar. 2025, [Online]. Available: <http://arxiv.org/abs/2406.05612>

- [14] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” Sep. 2020, [Online]. Available: <http://arxiv.org/abs/1905.11946>
- [15] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, “MobileNetV2: Inverted Residuals and Linear Bottlenecks,” Mar. 2019, [Online]. Available: <http://arxiv.org/abs/1801.04381>
- [16] L. Arora *et al.*, “Ensemble deep learning and EfficientNet for accurate diagnosis of diabetic retinopathy,” *Sci Rep*, vol. 14, no. 1, p. 30554, Dec. 2024, doi: 10.1038/s41598-024-81132-4.
- [17] F. Ahmed, “Addressing High Class Imbalance in Multi-Class Diabetic Retinopathy Severity Grading with Augmentation and Transfer Learning,” Jul. 2025, [Online]. Available: <http://arxiv.org/abs/2507.17121>
- [18] C. Mohanty *et al.*, “Using Deep Learning Architectures for Detection and Classification of Diabetic Retinopathy,” *Sensors*, vol. 23, no. 12, p. 5726, Jun. 2023, doi: 10.3390/s23125726.
- [19] G. Alwakid, W. Gouda, and M. Humayun, “Enhancement of Diabetic Retinopathy Prognostication Using Deep Learning, CLAHE, and ESRGAN,” *Diagnostics*, vol. 13, no. 14, p. 2375, Jul. 2023, doi: 10.3390/diagnostics13142375.
- [20] C. J. Hellín, A. A. Olmedo, A. Valledor, J. Gómez, M. López-Benítez, and A. Tayebi, “Unraveling the Impact of Class Imbalance on Deep-Learning Models for Medical Image Classification,” *Applied Sciences*, vol. 14, no. 8, p. 3419, Apr. 2024, doi: 10.3390/app14083419.
- [21] E. Pachetti and S. Colantonio, “A systematic review of few-shot learning in medical imaging,” *Artif Intell Med*, vol. 156, p. 102949, Oct. 2024, doi: 10.1016/j.artmed.2024.102949.
- [22] K. He, N. Pu, M. Lao, and M. S. Lew, “Few-shot and meta-learning methods for image understanding: a survey,” *Int J Multimed Inf Retr*, vol. 12, no. 2, p. 14, Dec. 2023, doi: 10.1007/s13735-023-00279-4.
- [23] J. Snell, K. Swersky, and R. S. Zemel, “Prototypical Networks for Few-shot Learning,” Jun. 2017, [Online]. Available: <http://arxiv.org/abs/1703.05175>
- [24] J. Y. Lim, K. M. Lim, C. P. Lee, and Y. X. Tan, “SSL-ProtoNet: Self-supervised Learning Prototypical Networks for few-shot learning,” *Expert Syst Appl*, vol. 238, p. 122173, Mar. 2024, doi: 10.1016/j.eswa.2023.122173.
- [25] N. Wang, Y. Lai, C. Chen, and Z. Zheng, “Prototypical networks with unlabeled data for few-shot node classification,” *Eng Appl Artif Intell*, vol. 145, p. 110088, Apr. 2025, doi: 10.1016/j.engappai.2025.110088.
- [26] A. Ouahab and O. Ben Ahmed, “ProtoMed: Prototypical networks with auxiliary regularization for few-shot medical image classification,” *Image Vis Comput*, vol. 154, p. 105337, Feb. 2025, doi: 10.1016/j.imavis.2024.105337.
- [27] X. Xu, D. Liu, G. Huang, M. Wang, M. Lei, and Y. Jia, “Computer aided diagnosis of diabetic retinopathy based on multi-view joint learning,” *Comput Biol Med*, vol. 174, p. 108428, May 2024, doi: 10.1016/j.combiomed.2024.108428.
- [28] Q. Abbas, Y. Daadaa, U. Rashid, M. Z. Sajid, and M. E. A. Ibrahim, “HDR-EfficientNet: A Classification of Hypertensive and Diabetic Retinopathy

- Using Optimize EfficientNet Architecture,” *Diagnostics*, vol. 13, no. 20, p. 3236, Oct. 2023, doi: 10.3390/diagnostics13203236.
- [29] S. Tummala, V. S. G. Thadikemalla, S. Kadry, M. Sharaf, and H. T. Rauf, “EfficientNetV2 Based Ensemble Model for Quality Estimation of Diabetic Retinopathy Images from DeepDRiD,” *Diagnostics*, vol. 13, no. 4, p. 622, Feb. 2023, doi: 10.3390/diagnostics13040622.
- [30] S.-L. Yi, X.-L. Yang, T.-W. Wang, F.-R. She, X. Xiong, and J.-F. He, “Diabetic Retinopathy Diagnosis Based on RA-EfficientNet,” *Applied Sciences*, vol. 11, no. 22, p. 11035, Nov. 2021, doi: 10.3390/app112211035.
- [31] M. Sushith, A. Sathiya, V. Kalaipoonguzhali, and V. Sathya, “A hybrid deep learning framework for early detection of diabetic retinopathy using retinal fundus images,” *Sci Rep*, vol. 15, no. 1, p. 15166, Apr. 2025, doi: 10.1038/s41598-025-99309-w.
- [32] W. Zhang, V. Belcheva, and T. Ermakova, “Interpretable Deep Learning for Diabetic Retinopathy: A Comparative Study of CNN, ViT, and Hybrid Architectures,” *Computers*, vol. 14, no. 5, p. 187, May 2025, doi: 10.3390/computers14050187.
- [33] H. Xu, X. Shao, D. Fang, and F. Huang, “A hybrid neural network approach for classifying diabetic retinopathy subtypes,” *Front Med (Lausanne)*, vol. 10, Jan. 2024, doi: 10.3389/fmed.2023.1293019.
- [34] M. Murugappan, N. B. Prakash, R. Jeya, A. Mohanarathinam, G. R. Hemalakshmi, and M. Mahmud, “A novel few-shot classification framework for diabetic retinopathy detection and grading,” *Measurement*, vol. 200, p. 111485, Aug. 2022, doi: 10.1016/j.measurement.2022.111485.
- [35] S. Tang *et al.*, “Few-shot medical image segmentation with high-fidelity prototypes,” *Med Image Anal*, vol. 100, p. 103412, Feb. 2025, doi: 10.1016/j.media.2024.103412.
- [36] S. Chamarthi, K. Fogelberg, J. Gawlikowski, and T. J. Brinker, “Few-shot learning for skin lesion classification: A prototypical networks approach,” *Inform Med Unlocked*, vol. 48, p. 101520, 2024, doi: 10.1016/j.imu.2024.101520.
- [37] H. Quan, X. Li, D. Hu, T. Nan, and X. Cui, “Dual-Channel Prototype Network for Few-Shot Pathology Image Classification,” *IEEE J Biomed Health Inform*, vol. 28, no. 7, pp. 4132–4144, Jul. 2024, doi: 10.1109/JBHI.2024.3386197.
- [38] B. Zhang, B. Gao, S. Liang, X. Li, and H. Wang, “A classification algorithm based on improved meta learning and transfer learning for few-shot medical images,” *IET Image Process*, vol. 17, no. 12, pp. 3589–3598, Oct. 2023, doi: 10.1049/ipr2.12889.
- [39] C. Gu and M. Lee, “Deep Transfer Learning Using Real-World Image Features for Medical Image Classification, with a Case Study on Pneumonia X-ray Images,” *Bioengineering*, vol. 11, no. 4, p. 406, Apr. 2024, doi: 10.3390/bioengineering11040406.
- [40] C. Su and W. Wang, “Concrete Cracks Detection Using Convolutional NeuralNetwork Based on Transfer Learning,” *Math Probl Eng*, vol. 2020, pp. 1–10, Oct. 2020, doi: 10.1155/2020/7240129.
- [41] S. Wang, Y. Wang, H. Liu, and Y. Sun, “Attribute-Guided Multi-Scale Prototypical Network for Few-Shot SAR Target Classification,” *IEEE J Sel*

- Top Appl Earth Obs Remote Sens*, vol. 14, pp. 12224–12245, 2021, doi: 10.1109/JSTARS.2021.3126688.
- [42] C.-L. Lin and K.-C. Wu, “Development of revised ResNet-50 for diabetic retinopathy detection,” *BMC Bioinformatics*, vol. 24, no. 1, p. 157, Apr. 2023, doi: 10.1186/s12859-023-05293-1.
- [43] J. E. Widyaya and S. Budi, “Pengaruh Preprocessing Terhadap Klasifikasi Diabetic Retinopathy dengan Pendekatan Transfer Learning Convolutional Neural Network,” *Jurnal Teknik Informatika dan Sistem Informasi*, vol. 7, no. 1, Apr. 2021, doi: 10.28932/jutisi.v7i1.3327.
- [44] S. Karthik; Maggie; Dane, “APTOS 2019 Blindness Detection,” Kaggle. Accessed: Oct. 21, 2025. [Online]. Available: <https://www.kaggle.com/competitions/aptos2019-blindness-detection>
- [45] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” Jan. 2017, [Online]. Available: <http://arxiv.org/abs/1412.6980>
- [46] J. Heaton, “Ian Goodfellow, Yoshua Bengio, and Aaron Courville: Deep learning,” *Genet Program Evolvable Mach*, vol. 19, no. 1–2, pp. 305–307, Jun. 2018, doi: 10.1007/s10710-017-9314-z.