



**PRA-SKRIPSI**

**METODE *HIBRIDA EFFICIENTNET-B0* DAN  
*PROTOTYPICAL NETWORK* UNTUK  
KLASIFIKASI MULTIKELAS *DIABETIC  
RETINOPATHY***

**ABI EKA PUTRA WULYONO  
NPM 22081010190**

**DOSEN PEMBIMBING**

Dr. Faisal Muttaqin, S.Kom, M.T  
Afina Lina Nurlaili, S.Kom., M.Kom.

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI  
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR  
FAKULTAS ILMU KOMPUTER  
PROGRAM STUDI INFORMATIKA  
SURABAYA  
2025**

## DAFTAR ISI

<b>DAFTAR ISI.....</b>	<b>i</b>
<b>BAB I PENDAHULUAN.....</b>	<b>1</b>
1.1. Latar Belakang .....	1
1.2. Rumusan Masalah .....	5
1.3. Batasan Masalah.....	5
1.4. Tujuan Penelitian .....	6
1.5. Manfaat Penelitian .....	6
<b>BAB II TINJAUAN PUSTAKA.....</b>	<b>8</b>
2.1. Penelitian Terdahulu .....	8
2.2. <i>Diabetic Retinopathy</i> (DR) .....	13
2.3. <i>EfficientNet-B0</i> .....	13
2.4. <i>Prototypical Network</i> .....	13
2.5. <i>Asia Pacific Tele-Ophthalmology Society</i> (APTOS) 2019 <i>Dataset</i> .....	13
2.6. <i>Preprocessing</i> .....	13
2.6.1. <i>Circle Crop</i> .....	13
2.6.2. <i>Ben Graham Preprocessing</i> .....	13
2.7. Metrik Evaluasi Klasifikasi.....	13
2.7.1. <i>Confusion Matrix</i> .....	13
2.7.2. <i>Accuracy</i> .....	13
2.7.3. <i>Precision</i> .....	13
2.7.4. <i>Recall</i> .....	13
2.7.5. <i>F1-Score</i> .....	13
2.7.6. <i>Macro-Averaging</i> .....	13
2.7.7. <i>Quadratic Weighted Kappa</i> (QWK) .....	13
<b>BAB III METODOLOGI .....</b>	<b>14</b>
3.1. Kebutuhan Perangkat .....	14
3.1.1. Perangkat Keras ( <i>Hardware</i> ) .....	14
3.1.2. Perangkat Lunak ( <i>Software</i> ).....	14
3.2. Tahapan Penelitian .....	14
3.3. Studi Literatur .....	14

3.4. Persiapan Data.....	14
3.4.1. APTOS <i>Dataset</i> 2019.....	14
3.4.2. Analisis Distribusi Kelas.....	14
3.4.3. Pembagian Data <i>Train</i> dan <i>Test</i> .....	14
3.5. Preprocessing .....	14
3.5.1. <i>Circle Crop</i> .....	14
3.5.2. Ben Graham <i>Preprocessing</i> .....	14
3.5.3. <i>Normalisasi</i> dan <i>Resize</i> .....	14
3.6. Pembangunan Model Hibrida .....	14
3.6.1. <i>EfficientNet-B0</i> sebagai <i>Feature Extractor</i> .....	14
3.6.2. <i>Prototypical Network</i> sebagai <i>Classifier</i> .....	14
3.6.3. Integrasi Hibrida <i>EfficientNet-B0</i> & <i>Prototypical Network</i> .....	14
3.7. <i>Train</i> dan <i>Test</i> Model.....	14
3.7.1. Proses <i>Train</i> Model.....	14
3.7.2. Metrik Evaluasi .....	14
3.8. Analisis Pengaruh Integrasi <i>Prototypical Network</i> .....	14
<b>DAFTAR PUSTAKA .....</b>	<b>15</b>

# **BAB I**

## **PENDAHULUAN**

### **1.1. Latar Belakang**

*Diabetic Retinopathy* (DR) merupakan komplikasi mikrovaskular dari diabetes mellitus yang menyebabkan kerusakan progresif pada pembuluh darah retina [1], [2]. Kondisi ini dapat berkembang menjadi gangguan penglihatan hingga kebutaan permanen jika tidak terdeteksi dan ditangani secara dini [3]. Berdasarkan hasil penelitian berskala global, prevalensi DR pada individu dengan diabetes mencapai 22,27%, dengan 6,17% di antaranya tergolong *vision-threatening Diabetic Retinopathy* (VTDR), dan angka ini diperkirakan meningkat menjadi 160,5 juta kasus pada tahun 2045 [4]. Penelitian lain juga menunjukkan bahwa jumlah penderita DR terus meningkat dalam 20 tahun terakhir, dari 10,9% pada tahun 2007 menjadi 20,8% pada tahun 2021, yang menunjukkan semakin besarnya beban penyakit ini di Masyarakat[5]. Berdasarkan karakteristik klinis yang diamati, *Diabetic Retinopathy* diklasifikasikan ke dalam beberapa tingkat keparahan, mulai dari stadium ringan hingga stadium lanjut yang bersifat proliferasif, di mana setiap tingkatan memerlukan pendekatan penanganan yang berbeda [6]. Mengingat progresivitas penyakit ini dapat dicegah melalui intervensi dini, deteksi dan klasifikasi *Diabetic Retinopathy* menjadi aspek krusial dalam manajemen kesehatan mata pada populasi penderita diabetes.

Deteksi *Diabetic Retinopathy* secara konvensional dilakukan melalui evaluasi citra fundus retina oleh tenaga medis spesialis oftalmologi. Dalam proses ini, dokter spesialis mengidentifikasi berbagai indikator patologi pada retina, seperti mikroaneurisma, perdarahan, eksudat, dan neovaskularisasi, untuk menentukan tingkat keparahan penyakit [7]. Meskipun metode ini dapat memberikan hasil yang akurat, proses pemeriksaan bergantung pada ketersediaan tenaga ahli dan dapat bervariasi dalam hal konsistensi interpretasi antar evaluator [8]. Keterbatasan ini mendorong pengembangan sistem berbasis komputer untuk mendukung proses diagnosis medis, yang dikenal sebagai *computer-aided diagnosis* (CAD). Sistem CAD bertujuan untuk menyediakan analisis objektif dan

konsisten terhadap citra medis, sehingga dapat membantu tenaga medis dalam proses pengambilan keputusan diagnostik [9].

Dalam bidang *computer-aided diagnosis*, metode *deep learning* telah banyak digunakan karena kemampuannya dalam mempelajari representasi fitur dari data secara otomatis tanpa memerlukan perancangan fitur manual [10]. *Convolutional Neural Network* (CNN) merupakan salah satu arsitektur *deep learning* yang paling banyak digunakan, dirancang untuk memproses data berbentuk *grid* seperti citra, melalui mekanisme konvolusi yang mampu mengenali pola spasial lokal secara efektif pada data visual [11]. Salah satu penelitian menunjukkan bahwa model CNN dapat mengklasifikasikan tingkat keparahan *Diabetic Retinopathy* hingga mencapai akurasi 90,6% [12].

Seiring dengan perkembangan arsitektur *deep learning*, berbagai varian CNN modern telah dikembangkan dengan fokus pada peningkatan efisiensi dan performa model. Beberapa arsitektur yang telah banyak digunakan dalam aplikasi *computer vision* antara lain *ResNet*, *DenseNet*, dan *EfficientNet* [13]. Di antara berbagai arsitektur tersebut, *EfficientNet* telah menunjukkan performa yang kompetitif dalam berbagai aplikasi *computer vision* dengan menggunakan pendekatan *compound scaling* untuk menyeimbangkan tiga dimensi jaringan neural, yaitu kedalaman, lebar, dan resolusi input [14]. Pendekatan ini memungkinkan peningkatan kapasitas model secara proporsional tanpa penambahan kompleksitas yang tidak efisien. *EfficientNet* memiliki beberapa varian dengan tingkat kompleksitas yang berbeda, mulai dari B0 hingga B7, di mana setiap varian mewakili *trade-off* antara akurasi dan efisiensi komputasi [14].

Varian *EfficientNet-B0* merupakan versi dasar dari keluarga *EfficientNet* yang dikembangkan melalui neural architecture search [14]. *EfficientNet-B0* memiliki jumlah parameter yang relatif lebih sedikit dibandingkan varian lainnya [14]. Arsitektur ini menggunakan *mobile inverted bottleneck convolution* (MBConv) sebagai *building block* utama, yang memungkinkan ekstraksi fitur secara efisien dengan penggunaan memori dan operasi komputasi yang lebih rendah [14], [15]. Karakteristik arsitektur *EfficientNet-B0* yang menerapkan *compound scaling* untuk menyeimbangkan kedalaman, lebar, dan resolusi jaringan menjadikannya sesuai sebagai backbone ekstraksi fitur pada aplikasi klasifikasi

citra medis, khususnya pada citra fundus retina yang memerlukan kemampuan mendeteksi detail halus seperti mikroaneurisma, perdarahan, dan eksudat [16].

Salah satu tantangan dalam pengembangan model klasifikasi *Diabetic Retinopathy* adalah distribusi data yang tidak seimbang antar kelas. *Dataset* publik yang digunakan dalam penelitian, seperti APTOS 2019, menunjukkan variasi jumlah sampel yang signifikan pada tiap tingkat keparahan, sehingga menimbulkan ketimpangan representasi antara kelas ringan, sedang, berat, dan proliferasi [17], [18], [19]. Ketidakseimbangan kelas pada *Dataset* medis dapat menyebabkan model *deep learning* cenderung bias terhadap kelas dengan jumlah sampel lebih banyak, sehingga performa pada kelas yang kurang terwakili menurun [20].

Salah satu pendekatan yang dikembangkan untuk mengatasi keterbatasan jumlah data beranotasi pada citra medis adalah *few-shot learning*, yaitu metode yang dapat mengurangi permasalahan kelangkaan data dan meningkatkan kecepatan serta ketahanan analisis citra medis dengan menggunakan jumlah contoh pelatihan yang terbatas per kelas [21]. *Few-shot learning* berbeda dengan supervised learning konvensional yang memerlukan data berlimpah untuk setiap kelas, karena berfokus pada pembelajaran representasi yang dapat digeneralisasi dari hanya beberapa contoh [21]. Dalam konteks *few-shot learning*, berbagai pendekatan *meta-learning* telah dikembangkan, yang umumnya dikategorikan menjadi tiga kelompok utama, yaitu *metric-based*, *model-based*, dan *optimization-based learning* [22]. Di antara ketiganya, pendekatan *metric-based learning* beroperasi dengan mempelajari fungsi jarak atau kesamaan (*similarity function*) dalam ruang *embedding*, sehingga model dapat membandingkan sampel baru dengan representasi kelas yang telah dipelajari selama proses *meta-training*.

*Prototypical Network* merupakan salah satu metode *metric-based few-shot learning* yang membangun representasi prototipe untuk setiap kelas dalam ruang *embedding* berdimensi tinggi [23]. Metode ini bekerja dengan menghitung *centroid* atau rata-rata dari *embedding* sampel *support set* untuk setiap kelas sebagai prototipe kelas tersebut [23], [24]. Klasifikasi sampel *query* kemudian dilakukan berdasarkan jarak *Euclidean* antara *embedding* sampel *query* dengan prototipe setiap kelas, di mana sampel diklasifikasikan ke kelas dengan jarak terdekat [23]. Pendekatan ini memungkinkan model untuk mengenali kelas dengan jumlah sampel

terbatas melalui pembelajaran representasi yang diskriminatif dalam ruang *embedding* [23], [25]. *Prototypical Network* telah diterapkan dalam berbagai domain klasifikasi, termasuk *computer vision* dan *medical imaging*, dengan hasil yang menunjukkan kemampuan dalam menangani kondisi data tidak seimbang [26].

Penelitian sebelumnya telah mengeksplorasi penggunaan *EfficientNet* sebagai *backbone* untuk ekstraksi fitur pada klasifikasi *Diabetic Retinopathy*, serta penerapan *Prototypical Network* untuk menangani kondisi *few-shot learning* pada berbagai domain aplikasi [16], [17], [18], [19], [24], [25], [26], [27]. Namun, berdasarkan penelusuran literatur, belum ditemukan penelitian yang secara spesifik mengembangkan model hibrida *EfficientNet-B0* dan *Prototypical Network* untuk klasifikasi multikelas *Diabetic Retinopathy* pada *Dataset APTOS 2019*. Model hibrida dalam konteks ini merujuk pada integrasi *end-to-end* antara *EfficientNet-B0* sebagai *feature extractor* dengan *Prototypical Network* sebagai *classifier*, di mana kedua komponen dilatih secara bersama-sama melalui *backpropagation* untuk mengoptimalkan representasi *embedding* dan pembentukan prototipe secara simultan. Pendekatan hibrida ini berbeda dengan pendekatan konvensional yang menggunakan *EfficientNet* dan metode klasifikasi secara terpisah, karena memungkinkan pembelajaran representasi fitur yang lebih adaptif terhadap karakteristik *few-shot learning* dan ketidakseimbangan distribusi kelas.

Berdasarkan permasalahan dan peluang yang telah diuraikan, penelitian ini bertujuan untuk mengembangkan model hibrida yang mengintegrasikan *EfficientNet-B0* sebagai *backbone* ekstraksi fitur dengan *Prototypical Network* sebagai mekanisme klasifikasi untuk menangani klasifikasi multikelas *Diabetic Retinopathy* dengan lima tingkat keparahan (0-4). Model hibrida ini dilatih secara *end-to-end*, memungkinkan optimasi bersama antara ekstraksi fitur dan pembentukan prototipe kelas. Penelitian ini diharapkan dapat memberikan kontribusi pada pengembangan metode klasifikasi *Diabetic Retinopathy*, khususnya dalam konteks penanganan ketidakseimbangan distribusi kelas melalui integrasi *few-shot learning* dengan arsitektur CNN yang efisien.

## 1.2. Rumusan Masalah

Berdasarkan uraian latar belakang yang telah dijelaskan, terdapat beberapa permasalahan utama yang perlu dipecahkan dalam penelitian ini, yaitu:

1. Bagaimana penerapan model hibrida *EfficientNet-B0* dan *Prototypical Network* untuk klasifikasi multikelas *Diabetic Retinopathy*?
2. Bagaimana pengaruh integrasi *Prototypical Network* terhadap performa klasifikasi dibandingkan model *baseline*?

## 1.3. Batasan Masalah

Berdasarkan penjabaran rumusan masalah yang telah disebutkan sebelumnya, terdapat beberapa batasan masalah yang ditentukan agar penelitian ini tidak terlalu luas dan lebih terfokus pada permasalahan yang akan diselesaikan. Berikut merupakan batasan masalah pada penelitian ini:

1. *Dataset* yang digunakan adalah APTOS 2019, sehingga hasil penelitian hanya diuji pada distribusi dan karakteristik *Dataset* tersebut. Data eksternal dari sumber lain tidak termasuk dalam lingkup pelatihan dan evaluasi.
2. Fokus penelitian terbatas pada citra fundus retina untuk klasifikasi multikelas *Diabetic Retinopathy* dengan lima tingkat keparahan (0: *No DR*, 1: *Mild*, 2: *Moderate*, 3: *Severe*, 4: *Proliferative DR*).
3. Penelitian menggunakan model hibrida dengan *EfficientNet-B0* sebagai *backbone feature extractor* dan *Prototypical Network* sebagai *classifier* yang dilatih secara *end-to-end*. Arsitektur *backbone* lain seperti *ResNet*, *DenseNet*, atau *transformer-based models* tidak termasuk dalam lingkup penelitian ini.
4. *Preprocessing* citra terbatas pada teknik *Circle Crop* dan Ben Graham *preprocessing*. Teknik augmentasi data sintetis atau metode *preprocessing* lainnya tidak digunakan untuk menjaga integritas informasi medis pada citra fundus.
5. Penanganan ketidakseimbangan kelas difokuskan pada pendekatan *few-shot learning* melalui *Prototypical Network*, tanpa menggunakan teknik *resampling* atau *synthetic data generation*.
6. Evaluasi performa model menggunakan metrik klasifikasi yang mencakup



*accuracy*, *macro-precision*, *macro-recall*, *macro-F1-score*, *confusion matrix*, dan *quadratic weighted kappa* (QWK) untuk menilai keseimbangan performa model dalam mengenali setiap kelas, khususnya pada kelas minoritas, pada *Dataset* APTOS 2019. Evaluasi dilakukan dengan pembagian data menjadi *training* dan *validation* set, tanpa pengujian pada *dataset* eksternal lainnya.

#### 1.4. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, penelitian ini mempunyai tujuan sebagai berikut:

1. Menerapkan model hibrida *EfficientNet-B0* dan *Prototypical Network* dalam klasifikasi multikelas citra *Diabetic Retinopathy*.
2. Menganalisis pengaruh integrasi *Prototypical Network* sebagai *classifier* terhadap performa klasifikasi dibandingkan dengan model *baseline*.

#### 1.5. Manfaat Penelitian

Berdasarkan tujuan penelitian yang telah disebutkan sebelumnya, didapatkan beberapa gambaran manfaat penelitian ini. Gambaran manfaat penelitian ini adalah sebagai berikut:

1. Bagi Peneliti, penelitian ini memberikan kesempatan untuk mengimplementasikan ilmu yang diperoleh selama perkuliahan, khususnya dalam bidang *deep learning*, *few-shot learning*, dan *computer-aided diagnosis* pada klasifikasi citra medis. Penelitian ini juga melatih kemampuan analisis dan pemecahan masalah dalam mengembangkan model hibrida serta strategi penanganan ketidakseimbangan kelas pada *Dataset* medis.
2. Bagi Bidang Kesehatan, hasil penelitian ini dapat menjadi kontribusi dalam pengembangan sistem *computer-aided diagnosis* untuk deteksi dan klasifikasi *Diabetic Retinopathy* secara objektif dan konsisten. Model yang dikembangkan berpotensi untuk mendukung tenaga medis dalam proses skrining *Diabetic Retinopathy*.

3. Bagi Akademisi dan Peneliti Lanjutan, penelitian ini dapat menjadi referensi bagi mahasiswa, peneliti, atau praktisi yang tertarik dalam pengembangan sistem berbasis *few-shot learning* dan integrasi arsitektur *EfficientNet-B0* untuk klasifikasi citra medis dengan ketidakseimbangan kelas. Selain itu, penelitian ini memperkaya literatur mengenai penerapan *Prototypical Network* pada domain *medical imaging* dan dapat menjadi dasar pengembangan metode serupa pada penyakit atau modalitas citra medis lainnya.

## BAB II

### TINJAUAN PUSTAKA

#### 2.1. Penelitian Terdahulu

Perkembangan teknologi *deep learning* telah membuka peluang besar dalam klasifikasi citra fundus retina dengan berbagai pendekatan arsitektur, mulai dari CNN konvensional hingga model hibrida yang mengombinasikan beberapa metode modern. Pendekatan ini memungkinkan model untuk mengekstraksi fitur spasial dan tekstur kompleks dari citra retina secara efisien serta menyesuaikan diri terhadap variasi kualitas citra. Penelitian ini berfokus pada pengembangan model hibrida yang mengintegrasikan *EfficientNet-B0* sebagai *feature extractor* dengan *Prototypical Network* sebagai *classifier* untuk klasifikasi multikelas DR menggunakan *dataset* APTOS 2019. Tujuan utamanya adalah mengevaluasi bagaimana integrasi *few-shot learning* dapat meningkatkan performa model baseline dalam menangani distribusi data yang tidak seimbang.

Penelitian sebelumnya dalam [16] mengembangkan pendekatan *ensemble deep learning* berbasis *EfficientNet* untuk diagnosis DR yang lebih akurat. Dengan menggabungkan beberapa varian *EfficientNet* melalui strategi voting ensemble, model ini mampu meningkatkan akurasi di atas 90% serta memperbaiki sensitivitas terhadap kelas minoritas. Hasil tersebut menunjukkan bahwa pendekatan *ensemble* dapat mengurangi kesalahan klasifikasi dan meningkatkan kestabilan performa antar kelas, sehingga menjadi dasar penting bagi pengembangan arsitektur yang lebih adaptif terhadap variasi tingkat keparahan DR.

Studi lain dalam [28] memperkenalkan *HDR-EfficientNet*, arsitektur yang dioptimalkan untuk klasifikasi gabungan *Hypertensive Retinopathy* dan DR. Model ini mengombinasikan optimisasi *hyperparameter* dan *data augmentation* untuk memperkuat kemampuan generalisasi pada *dataset* yang tidak seimbang. Dengan akurasi mencapai lebih dari 92%, penelitian ini menegaskan bahwa penyetelan arsitektur dan pemrosesan data memainkan peran krusial dalam peningkatan kinerja model *EfficientNet* di domain medis.

Penelitian selanjutnya dalam [17] berfokus pada penerapan *transfer*

*learning* menggunakan *EfficientNetB0* dengan teknik augmentasi data untuk mengatasi masalah ketidakseimbangan kelas dalam klasifikasi tingkat keparahan DR. Dengan *dataset* dari *Kaggle* yang terbatas dan tidak seimbang, model ini berhasil mencapai akurasi rata-rata 85%. Studi ini memperluas pemahaman mengenai efektivitas transfer learning pada kondisi data minoritas, sekaligus menunjukkan efisiensi *EfficientNet* sebagai *backbone* ringan dengan performa kompetitif.

Studi dalam [29] mengusulkan *ensemble* model berbasis *EfficientNetV2* untuk menilai kualitas citra DR sebelum klasifikasi utama dilakukan. Tujuannya adalah memastikan hanya citra berkualitas tinggi yang digunakan dalam tahap diagnosis otomatis. Dengan akurasi 88,7%, model ini membuktikan bahwa integrasi modul *quality control* dapat meningkatkan reliabilitas hasil klasifikasi dan mengurangi kesalahan akibat citra yang buram atau tidak fokus.

Sementara itu, penelitian dalam [30] kemudian memperkenalkan *RA-EfficientNet* (*Residual Attention EfficientNet*), yang menambahkan mekanisme *attention* untuk mendeteksi area patologis penting pada citra retina. Dengan akurasi 91,2% dan *loss* sebesar 0,42, model ini mengungguli *EfficientNet* standar, khususnya dalam identifikasi lesi mikroskopis. Pendekatan ini menunjukkan bahwa integrasi *attention mechanism* dapat meningkatkan fokus model pada fitur yang relevan secara klinis.

Selanjutnya, pengembangan model hibrida CNN-RNN dalam [31] memperluas konsep *deep learning* untuk deteksi dini DR. Dengan lebih dari 35.000 citra retina dari *dataset Kaggle*, model ini mencapai akurasi 86,53%. Penelitian ini menambahkan dimensi temporal terhadap analisis citra medis, yang melengkapi pengembangan arsitektur *EfficientNet* dalam memahami urutan spasial dan temporal pada data visual.

Studi lain dalam [32] melakukan perbandingan antara CNN, *Vision Transformer* (ViT), dan model hibrida CNN-*Transformer* untuk klasifikasi DR. Hasil eksperimen menunjukkan hasil akurasi tertinggi sebesar 90,1% serta meningkatkan interpretabilitas hasil klasifikasi. Penelitian ini menegaskan bahwa penggabungan arsitektur konvolusional dan *attention-based* dapat menghasilkan model yang lebih transparan dan akurat dalam konteks medis.

Sejalan dengan sebelumnya, penelitian dalam [33] juga mengembangkan model hibrida yang mengintegrasikan arsitektur berbasis CNN dan *Transformer*, yakni *EfficientNet* dan *Swin Transformer* untuk prediksi DR. Integrasi ini memungkinkan model memanfaatkan fitur lokal (*local features*) dari *EfficientNet* dan fitur global (*contextual features*) dari *Transformer*. Hasil evaluasi menunjukkan akurasi 97% dengan sensitivitas 0,95 dan spesifisitas 0,98, menegaskan efektivitas kombinasi dua paradigma representasi fitur tersebut.

Penelitian dalam [34] memperkenalkan *DRNet* berbasis *Prototypical Network* untuk *few-shot classification* DR. Model ini memanfaatkan *episodic learning* dan *attention mechanism* untuk memperkuat representasi fitur antar kelas. Dengan akurasi 99,73% untuk deteksi DR dan 98,18% untuk grading, penelitian ini menunjukkan potensi besar *ProtoNet* dalam menangani keterbatasan data dan ketidakseimbangan kelas pada domain medis.

Studi dalam [26] kemudian mengembangkan *ProtoMed*, yaitu *Prototypical Network* dengan *auxiliary regularization* untuk klasifikasi citra medis berbasis *few-shot learning*. Pendekatan ini memperbaiki stabilitas dan generalisasi fitur pada *dataset* kecil, sekaligus meningkatkan akurasi model dalam mengenali kelas baru dengan jumlah data latih minimal.

Penelitian selanjutnya dalam [35] melanjutkan penelitian pada ranah segmentasi citra medis dengan mengusulkan metode *Few-Shot Medical Image Segmentation* menggunakan *high-fidelity prototypes*. Pendekatan ini menitikberatkan pada pembentukan prototipe berkualitas tinggi yang mampu mendukung segmentasi presisi tinggi. Hasil penelitian ini memperkuat efektivitas pendekatan berbasis *ProtoNet* untuk tugas-tugas medis yang kompleks seperti segmentasi jaringan.

Studi dalam [36] menerapkan *Prototypical Network* pada klasifikasi lesi kulit, menunjukkan kemampuannya mengenali berbagai tipe lesi meskipun jumlah data pelatihan terbatas. Hasil penelitian ini mempertegas keunggulan *few-shot learning* dalam mengatasi kelangkaan data, memperkuat dasar pemikiran integrasi *ProtoNet* ke dalam tugas klasifikasi medis lainnya.

Penelitian dalam [37] memperkenalkan *Dual-Channel Prototype Network* untuk klasifikasi citra patologi. Model ini menggunakan dua saluran prototipe, yaitu

saluran visual dan semantik, yang bekerja paralel untuk meningkatkan akurasi identifikasi jaringan patologis. Hasilnya menunjukkan peningkatan efisiensi komputasi sekaligus akurasi klasifikasi, menjadikannya salah satu pengembangan signifikan dari pendekatan *ProtoNet* klasik.

Sementara itu, studi dalam [38] mengembangkan algoritma *improved meta-learning* dan *transfer learning* untuk *few-shot medical image classification*. Model ini dirancang agar mampu mentransfer pengetahuan dari domain besar ke domain kecil, memperkuat kemampuan generalisasi lintas penyakit. Penelitian ini memperluas konsep *Prototypical Network* dengan fokus pada adaptasi cepat di berbagai domain medis.

Selain itu, penelitian dalam [18] mengombinasikan *DenseNet* dan VGG-CNN untuk deteksi serta klasifikasi DR. Pendekatan ini menunjukkan peningkatan signifikan dalam akurasi dan F1-score dibandingkan model tunggal. Hasil tersebut menegaskan potensi integrasi beberapa arsitektur CNN dalam meningkatkan ketepatan diagnosis otomatis berbasis citra fundus.

Studi dalam [39] menunjukkan bahwa penerapan *Deep Transfer Learning* berbasis jaringan konvolusional mampu mencapai efisiensi pelatihan tinggi dan konvergensi cepat bahkan pada *dataset* berkualitas rendah. Pendekatan ini memperluas penerapan teknik *transfer learning* di luar domain *Diabetic Retinopathy* (DR) dan memperkuat relevansi prinsip integrasi model hibrida pada berbagai aplikasi medis.

Dari berbagai penelitian terdahulu, terlihat tren peningkatan performa klasifikasi DR melalui pengembangan arsitektur *EfficientNet* yang dioptimalkan, penerapan model hibrida seperti CNN-*Transformer*, serta pemanfaatan *Prototypical Network* untuk mengatasi keterbatasan data pada *few-shot learning*. Pendekatan hibrida terbukti efektif mengekstraksi fitur kompleks dan memperkuat generalisasi model, sedangkan *ProtoNet* unggul dalam mengenali kelas dengan data terbatas. Kesenjangan penelitian yang ada terletak pada penerapan model hibrida *EfficientNet-Prototypical Network* secara *end-to-end* pada data medis tidak seimbang. Penelitian ini berfokus pada integrasi *EfficientNet-B0* dan *Prototypical Network* untuk klasifikasi multikelas DR dengan pendekatan *few-shot learning* yang dilatih bersamaan guna mencapai keseimbangan performa antar kelas.

**Tabel 2.1 Penelitian Terdahulu**

<b>No</b>	<b>Judul</b>	<b>Metode</b>	<b>Hasil Utama</b>
<b>1</b>	<i>Ensemble Deep Learning Approach for Diabetic Retinopathy Classification Using EfficientNet [16]</i>	<i>Ensemble EfficientNet</i>	Akurasi di atas 90% dan meningkatkan sensitivitas kelas minor
<b>2</b>	<i>HDR-EfficientNet: Hybrid Deep Learning Model for Hypertensive Retinopathy and Diabetic Retinopathy [28]</i>	<i>Optimized EfficientNet dengan augmentasi</i>	Akurasi lebih dari 92%, performa lebih baik dibanding CNN konvensional
<b>3</b>	<i>EfficientNetB0 Transfer Learning for Severity Classification of Diabetic Retinopathy [17]</i>	<i>Transfer learning + data augmentation</i>	Akurasi rata-rata 85%, efektif menangani kelas minor
<b>4</b>	<i>EfficientNetV2-Based Ensemble Model for Pre-Diagnostic Image Quality Assessment in Diabetic Retinopathy [29]</i>	<i>Ensemble EfficientNetV2</i>	Akurasi 88,7%, menilai kualitas citra sebelum klasifikasi
<b>5</b>	<i>A Novel Few-Shot Classification Framework for Diabetic Retinopathy Detection and Grading [34]</i>	<i>Prototypical Network dengan episodic learning</i>	Akurasi deteksi 99,73%, grading 98,18%
<b>6</b>	<i>ProtoMed: Prototypical Network with Auxiliary Regularization for Few-Shot Medical Image Classification [26]</i>	<i>Prototypical Network few-shot</i>	Representasi fitur stabil, akurasi meningkat
<b>7</b>	<i>Dual-Channel Prototype Network for Few-Shot Pathology Image Classification [37]</i>	<i>Dual-channel Prototypical Network</i>	Akurasi 85,2 persen pada 10-shot dengan peningkatan 6,81 persen dibanding <i>ProtoNet</i>
<b>8</b>	<i>A Hybrid Neural Network Approach for Classifying Diabetic Retinopathy Subtypes [33]</i>	<i>Hybrid EfficientNet + Swin Transformer</i>	Akurasi 97%, sensitivitas 0,95, spesifisitas 0,98

**2.2. *Diabetic Retinopathy (DR)***

**2.3. *EfficientNet-B0***

**2.4. *Prototypical Network***

**2.5. *Asia Pacific Tele-Ophthalmology Society (APTOS) 2019 Dataset***

**2.6. *Preprocessing***

**2.6.1. *Circle Crop***

**2.6.2. *Ben Graham Preprocessing***

**2.7. *Metrik Evaluasi Klasifikasi***

**2.7.1. *Confusion Matrix***

**2.7.2. *Accuracy***

**2.7.3. *Precision***

**2.7.4. *Recall***

**2.7.5. *F1-Score***

**2.7.6. *Macro-Averaging***

**2.7.7. *Quadratic Weighted Kappa (QWK)***



## **BAB III**

### **METODOLOGI**

#### **3.1. Kebutuhan Perangkat**

##### **3.1.1. Perangkat Keras (*Hardware*)**

##### **3.1.2. Perangkat Lunak (*Software*)**

#### **3.2. Tahapan Penelitian**

#### **3.3. Studi Literatur**

#### **3.4. Persiapan Data**

##### **3.4.1. APTOS *Dataset* 2019**

##### **3.4.2. Analisis Distribusi Kelas**

##### **3.4.3. Pembagian Data *Train* dan *Test***

#### **3.5. Preprocessing**

##### **3.5.1. *Circle Crop***

##### **3.5.2. Ben Graham *Preprocessing***

##### **3.5.3. *Normalisasi* dan *Resize***

#### **3.6. Pembangunan Model Hibrida**

##### **3.6.1. *EfficientNet-B0* sebagai *Feature Extractor***

##### **3.6.2. *Prototypical Network* sebagai *Classifier***

##### **3.6.3. Integrasi Hibrida *EfficientNet-B0* & *Prototypical Network***

#### **3.7. *Train* dan *Test* Model**

##### **3.7.1. Proses *Train* Model**

##### **3.7.2. Metrik Evaluasi**

#### **3.8. Analisis Pengaruh Integrasi *Prototypical Network***

## DAFTAR PUSTAKA

- [1] R. Singh, A. Walia, J. Kaur, P. Kumar, I. Verma, and N. Rani, "Diabetic Retinopathy - Pathophysiology to Treatment: A Review," *Curr Diabetes Rev*, vol. 21, no. 3, Mar. 2025, doi: 10.2174/0115733998259940231105200251.
- [2] M. Kropp *et al.*, "Diabetic retinopathy as the leading cause of blindness and early predictor of cascading complications—risks and mitigation," *EPMA Journal*, vol. 14, no. 1, pp. 21–42, Feb. 2023, doi: 10.1007/s13167-023-00314-8.
- [3] D. D. Chong, N. Das, and R. P. Singh, "Diabetic retinopathy: Screening, prevention, and treatment," *Cleve Clin J Med*, vol. 91, no. 8, pp. 503–510, Aug. 2024, doi: 10.3949/ccjm.91a.24028.
- [4] Z. L. Teo *et al.*, "Global Prevalence of Diabetic Retinopathy and Projection of Burden through 2045," *Ophthalmology*, vol. 128, no. 11, pp. 1580–1591, Nov. 2021, doi: 10.1016/j.ophtha.2021.04.027.
- [5] B. L. VanderBeek, Y. Yu, S. Cardillo, and R. Hubbard, "Twenty-Year Trends in Prevalence and Incidence of Diabetic Retinal Disease," *Ophthalmology*, vol. 132, no. 7, pp. 767–774, Jul. 2025, doi: 10.1016/j.ophtha.2025.01.022.
- [6] Z. Yang, T.-E. Tan, Y. Shao, T. Y. Wong, and X. Li, "Classification of diabetic retinopathy: Past, present and future," *Front Endocrinol (Lausanne)*, vol. 13, Dec. 2022, doi: 10.3389/fendo.2022.1079217.
- [7] C. J. Flaxel *et al.*, "Diabetic Retinopathy Preferred Practice Pattern®," *Ophthalmology*, vol. 127, no. 1, pp. P66–P145, Jan. 2020, doi: 10.1016/j.ophtha.2019.09.025.
- [8] S. Srinivasan *et al.*, "Inter-observer agreement in grading severity of diabetic retinopathy in wide-field fundus photographs," *Eye*, vol. 37, no. 6, pp. 1231–1235, Apr. 2023, doi: 10.1038/s41433-022-02107-1.
- [9] Y. A. Kadhim, M. U. Khan, and A. Mishra, "Deep Learning-Based Computer-Aided Diagnosis (CAD): Applications for Medical Image Datasets," *Sensors*, vol. 22, no. 22, p. 8999, Nov. 2022, doi: 10.3390/s22228999.
- [10] S. K. Zhou *et al.*, "A Review of Deep Learning in Medical Imaging: Imaging Traits, Technology Trends, Case Studies With Progress Highlights, and Future Promises," *Proceedings of the IEEE*, vol. 109, no. 5, pp. 820–838, May 2021, doi: 10.1109/JPROC.2021.3054390.
- [11] L. Alzubaidi *et al.*, "Review of deep learning: concepts, CNN architectures, challenges, applications, future directions," *J Big Data*, vol. 8, no. 1, p. 53, Mar. 2021, doi: 10.1186/s40537-021-00444-8.
- [12] C. Suedumrong, S. Phongmoo, T. Akarajaka, and K. Leksakul, "Diabetic Retinopathy Detection Using Convolutional Neural Networks with Background Removal, and Data Augmentation," *Applied Sciences*, vol. 14, no. 19, p. 8823, Sep. 2024, doi: 10.3390/app14198823.
- [13] P. Jeevan and A. Sethi, "Which Backbone to Use: A Resource-efficient Domain Specific Comparison for Computer Vision," Mar. 2025, [Online]. Available: <http://arxiv.org/abs/2406.05612>

- [14] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," Sep. 2020, [Online]. Available: <http://arxiv.org/abs/1905.11946>
- [15] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," Mar. 2019, [Online]. Available: <http://arxiv.org/abs/1801.04381>
- [16] L. Arora *et al.*, "Ensemble deep learning and EfficientNet for accurate diagnosis of diabetic retinopathy," *Sci Rep*, vol. 14, no. 1, p. 30554, Dec. 2024, doi: 10.1038/s41598-024-81132-4.
- [17] F. Ahmed, "Addressing High Class Imbalance in Multi-Class Diabetic Retinopathy Severity Grading with Augmentation and Transfer Learning," Jul. 2025, [Online]. Available: <http://arxiv.org/abs/2507.17121>
- [18] C. Mohanty *et al.*, "Using Deep Learning Architectures for Detection and Classification of Diabetic Retinopathy," *Sensors*, vol. 23, no. 12, p. 5726, Jun. 2023, doi: 10.3390/s23125726.
- [19] G. Alwakid, W. Gouda, and M. Humayun, "Enhancement of Diabetic Retinopathy Prognostication Using Deep Learning, CLAHE, and ESRGAN," *Diagnostics*, vol. 13, no. 14, p. 2375, Jul. 2023, doi: 10.3390/diagnostics13142375.
- [20] C. J. Hellín, A. A. Olmedo, A. Valledor, J. Gómez, M. López-Benítez, and A. Tayebi, "Unraveling the Impact of Class Imbalance on Deep-Learning Models for Medical Image Classification," *Applied Sciences*, vol. 14, no. 8, p. 3419, Apr. 2024, doi: 10.3390/app14083419.
- [21] E. Pachetti and S. Colantonio, "A systematic review of few-shot learning in medical imaging," *Artif Intell Med*, vol. 156, p. 102949, Oct. 2024, doi: 10.1016/j.artmed.2024.102949.
- [22] K. He, N. Pu, M. Lao, and M. S. Lew, "Few-shot and meta-learning methods for image understanding: a survey," *Int J Multimed Inf Retr*, vol. 12, no. 2, p. 14, Dec. 2023, doi: 10.1007/s13735-023-00279-4.
- [23] J. Snell, K. Swersky, and R. S. Zemel, "Prototypical Networks for Few-shot Learning," Jun. 2017, [Online]. Available: <http://arxiv.org/abs/1703.05175>
- [24] J. Y. Lim, K. M. Lim, C. P. Lee, and Y. X. Tan, "SSL-ProtoNet: Self-supervised Learning Prototypical Networks for few-shot learning," *Expert Syst Appl*, vol. 238, p. 122173, Mar. 2024, doi: 10.1016/j.eswa.2023.122173.
- [25] N. Wang, Y. Lai, C. Chen, and Z. Zheng, "Prototypical networks with unlabeled data for few-shot node classification," *Eng Appl Artif Intell*, vol. 145, p. 110088, Apr. 2025, doi: 10.1016/j.engappai.2025.110088.
- [26] A. Ouahab and O. Ben Ahmed, "ProtoMed: Prototypical networks with auxiliary regularization for few-shot medical image classification," *Image Vis Comput*, vol. 154, p. 105337, Feb. 2025, doi: 10.1016/j.imavis.2024.105337.
- [27] X. Xu, D. Liu, G. Huang, M. Wang, M. Lei, and Y. Jia, "Computer aided diagnosis of diabetic retinopathy based on multi-view joint learning," *Comput Biol Med*, vol. 174, p. 108428, May 2024, doi: 10.1016/j.compbiomed.2024.108428.
- [28] Q. Abbas, Y. Daadaa, U. Rashid, M. Z. Sajid, and M. E. A. Ibrahim, "HDR-EfficientNet: A Classification of Hypertensive and Diabetic Retinopathy

- Using Optimize EfficientNet Architecture,” *Diagnostics*, vol. 13, no. 20, p. 3236, Oct. 2023, doi: 10.3390/diagnostics13203236.
- [29] S. Tummala, V. S. G. Thadikemalla, S. Kadry, M. Sharaf, and H. T. Rauf, “EfficientNetV2 Based Ensemble Model for Quality Estimation of Diabetic Retinopathy Images from DeepDRiD,” *Diagnostics*, vol. 13, no. 4, p. 622, Feb. 2023, doi: 10.3390/diagnostics13040622.
  - [30] S.-L. Yi, X.-L. Yang, T.-W. Wang, F.-R. She, X. Xiong, and J.-F. He, “Diabetic Retinopathy Diagnosis Based on RA-EfficientNet,” *Applied Sciences*, vol. 11, no. 22, p. 11035, Nov. 2021, doi: 10.3390/app112211035.
  - [31] M. Sushith, A. Sathiya, V. Kalaipoonguzhali, and V. Sathya, “A hybrid deep learning framework for early detection of diabetic retinopathy using retinal fundus images,” *Sci Rep*, vol. 15, no. 1, p. 15166, Apr. 2025, doi: 10.1038/s41598-025-99309-w.
  - [32] W. Zhang, V. Belcheva, and T. Ermakova, “Interpretable Deep Learning for Diabetic Retinopathy: A Comparative Study of CNN, ViT, and Hybrid Architectures,” *Computers*, vol. 14, no. 5, p. 187, May 2025, doi: 10.3390/computers14050187.
  - [33] H. Xu, X. Shao, D. Fang, and F. Huang, “A hybrid neural network approach for classifying diabetic retinopathy subtypes,” *Front Med (Lausanne)*, vol. 10, Jan. 2024, doi: 10.3389/fmed.2023.1293019.
  - [34] M. Murugappan, N. B. Prakash, R. Jeya, A. Mohanarathinam, G. R. Hemalakshmi, and M. Mahmud, “A novel few-shot classification framework for diabetic retinopathy detection and grading,” *Measurement*, vol. 200, p. 111485, Aug. 2022, doi: 10.1016/j.measurement.2022.111485.
  - [35] S. Tang *et al.*, “Few-shot medical image segmentation with high-fidelity prototypes,” *Med Image Anal*, vol. 100, p. 103412, Feb. 2025, doi: 10.1016/j.media.2024.103412.
  - [36] S. Chamarthi, K. Fogelberg, J. Gawlikowski, and T. J. Brinker, “Few-shot learning for skin lesion classification: A prototypical networks approach,” *Inform Med Unlocked*, vol. 48, p. 101520, 2024, doi: 10.1016/j.imu.2024.101520.
  - [37] H. Quan, X. Li, D. Hu, T. Nan, and X. Cui, “Dual-Channel Prototype Network for Few-Shot Pathology Image Classification,” *IEEE J Biomed Health Inform*, vol. 28, no. 7, pp. 4132–4144, Jul. 2024, doi: 10.1109/JBHI.2024.3386197.
  - [38] B. Zhang, B. Gao, S. Liang, X. Li, and H. Wang, “A classification algorithm based on improved meta learning and transfer learning for few-shot medical images,” *IET Image Process*, vol. 17, no. 12, pp. 3589–3598, Oct. 2023, doi: 10.1049/ipr2.12889.
  - [39] C. Gu and M. Lee, “Deep Transfer Learning Using Real-World Image Features for Medical Image Classification, with a Case Study on Pneumonia X-ray Images,” *Bioengineering*, vol. 11, no. 4, p. 406, Apr. 2024, doi: 10.3390/bioengineering11040406.